

**MÁSTER EN BUSINESS ANALYTICS, INTELIGENCIA ARTIFICIAL Y MACHINE
LEARNING**

“Salud digital”

Alejandro Magdiel Muñoz Corona

Tutor Manuel de Luna Amat

Curso académico 2024/2025

Universidad Francisco de Vitoria

**MODELADO DE LA COMPOSICIÓN DE CARBOHIDRATOS INGERIDOS
UTILIZANDO RESPUESTA GLUCÉMICA POSTPRANDIAL, DATOS FISIOLÓGICOS,
CLÍNICOS Y DEL MICROBIOMA MEDIANTE APRENDIZAJE AUTOMÁTICO**

A mi madre, por su fortaleza inquebrantable y su amor incondicional.

A mi padre, por su apoyo constante y su ejemplo.

A mis hermanos, por ser compañeros de vida y fuente de inspiración.

Y a mi familia, por ser el motor que impulsa cada uno de mis pasos.

AGRADECIMIENTOS

Quiero expresar mi más profundo agradecimiento a todas las personas que hicieron posible la realización de este Trabajo de Fin de Máster.

En primer lugar, a mi tutor y uno de los mejores profesores que he tenido el privilegio de conocer, Manuel de Luna Amat, por su entrega en transmitir conocimiento de valor y fomentar una comprensión profunda del mismo. Su pasión por aquello que podemos aprender de los datos ha sido una fuente constante de inspiración. Me llevo conmigo cada consejo, tanto técnico como humano. Gracias por su paciencia, cercanía y cada valiosa sugerencia.

A Amadeo y Fernando, por despertar en mí un entusiasmo renovado por el aprendizaje y a todo el profesorado del máster, por su compromiso y entrega. Gracias por compartir su experiencia con generosidad y por hacer que cada clase se sintiera como una oportunidad valiosa de crecimiento.

A los directivos, por diseñar un programa retador, por reunir a un grupo extraordinario de profesionales para impartirlo, y por su acompañamiento cercano en cada etapa del proceso.

Especialmente, gracias a mis compañeros, quienes alegraron cada tarde de clase y compartieron conmigo este camino. Los nueve me han enseñado valiosas lecciones y tienen en mí un amigo para siempre.

A Carlos, Michael y Jorge por su cariño, su amabilidad y su amistad sin reservas. Porque me hicieron sentir como en casa en un lugar lejano. A los tres, gracias por las aventuras, las risas y por estar presentes en este viaje.

A Ben y Antonio, por su cercanía, por estar siempre pendientes y por acompañarme con su amistad y sus palabras a lo largo de este camino.

A mi familia, por su apoyo y amor incondicional, por su comprensión y por recordarme siempre la importancia de perseverar. Ningún logro valdría la pena si no estuvieran ustedes para compartirlo conmigo.

Finalmente, gracias a todas aquellas personas que, de una u otra forma, contribuyeron a este proyecto. Sin ustedes, este trabajo no se sentiría tan satisfactorio como se siente.

DECLARACIÓN PERSONAL DE NO PLAGIO

Yo, D/Dña Alejandro Magdiel Muñiz Corona con NIF/NIE Z2130020H estudiante del **Máster en Business Analytics, Inteligencia Artificial y Machine Learning** de la Universidad de Francisco de Vitoria, como autor/a de este documento académico, titulado *“Modelado de la composición de carbohidratos ingeridos utilizando respuesta glucémica postprandial, datos fisiológicos, clínicos y del microbioma mediante aprendizaje automático”* presentado como **Trabajo de Fin de Máster**, para la obtención del Título correspondiente, **declaro que, es fruto de mi trabajo personal, que no copio, que no utilizo ideas, formulaciones, citas integrales e ilustraciones diversas, sacadas de cualquier obra, artículo, memoria, etc., (en versión impresa o electrónica), sin mencionar de forma clara y estricta su origen, tanto en el cuerpo del texto como en la bibliografía.**

Así mismo, soy plenamente consciente de que el hecho de no respetar estos extremos es objeto de sanciones universitarias y/o de otro orden.

En Madrid a 1 de junio de 2025.

Fdo.

A handwritten signature in black ink, appearing to read 'Alejandro Magdiel Muñiz Corona', written in a cursive style.

ÍNDICE

1. INTRODUCCIÓN	1
1.1. Modelos de aprendizaje automático como herramienta para afrontar el desafío de la monitorización continua	5
2. OBJETIVOS.....	7
2.1. Objetivo General	7
2.2. Objetivos Específicos	7
3. ESTADO DEL ARTE	8
3.1. Importancia de los carbohidratos y la dieta en el control glucémico	8
3.2. Respuesta glucémica postprandial	9
3.3. Índice glucémico, carga glucémica y área incremental bajo la curva (iAUC)	11
3.4. Monitorización continua de glucosa (CGM)	15
3.4.1. Abbott FreeStyle Libre Pro	16
3.4.2. Dexcom G6 Pro.....	17
3.5. Apps y métodos actuales para registro alimentario	18
3.5.1. Precisión del conteo de macronutrientes y errores sistemáticos	19
3.5.2. Fuentes de error en el registro dietético con apps	20
3.6. Modelos de machine learning en salud metabólica	21
3.7. Predicciones en la ingesta alimentaria y macronutrientes	22
3.8. Aplicaciones clínicas y tecnológicas	24
3.9. La necesidad de soluciones automáticas sin registro manual.....	25
4. METODOLOGÍA	28
4.1. Conjunto de datos	28
4.2. Procesamiento de datos	30
4.2.1. Tratamiento del conjunto de datos “ <i>microbes</i> ”	31
4.2.2. Tratamiento del conjunto de datos “ <i>meals</i> ”	32
4.3. Extracción de eventos de comida	33
4.4. Cálculos de métricas glucémicas	35

4.5.	Análisis exploratorio	38
4.6.	Modelado	41
4.7.	<i>Clustering</i>	42
4.8.	Segundo modelo	43
5.	RESULTADOS	44
5.1.	Análisis descriptivo de los datos	44
5.1.1.	Conjunto de comidas “ <i>meals</i> ”	44
5.1.2.	Conjunto de datos “ <i>bio</i> ”	48
5.1.3.	Conjunto de datos “ <i>gut_scores_imputed</i> ”	49
5.1.4.	Respuesta glucémica postprandial	51
5.2.	Resultados del modelado	57
5.2.1.	RandomForestRegressor	57
5.2.2.	XGBRegressor	61
5.2.2.1.	Con transformación logarítmica de la variable carbs	63
5.2.3.	Modelo de Stacking	64
5.2.4.	Clustering	65
5.2.4.1.	XGBRegressor con variable de cluster	67
5.3.	Discusión de resultados	68
6.	APLICACIONES Y LÍNEAS FUTURAS	71
6.1.	Propuesta de despliegue en Cloud	71
6.1.1.	Justificación del despliegue	71
6.1.2.	Arquitectura general propuesta	71
6.1.3.	Flujo de datos	73
6.1.4.	Seguridad y privacidad	74
6.1.5.	Monitorización del sistema	74
6.2.	Posibles mejoras del modelo	75
6.3.	Predicción en contexto de eventos de comida y en tiempo real	76
7.	CONCLUSIONES	77

8.	BIBLIOGRAFÍA.....	79
9.	ANEXOS.....	87
	Anexo I	87
	Anexo II	87
	Anexo III	87

1. INTRODUCCIÓN

Existen diversas enfermedades humanas que se relacionan estrechamente con los niveles de glucosa pues, aunque se pueden manifestar de distintas maneras, la alteración en la regulación de la glucosa en el organismo es el común denominador. Entre estas enfermedades se encuentra la diabetes mellitus, la cual se ha convertido en un problema de salud global de primer orden debido a su rápida expansión y por sus terribles consecuencias. De acuerdo con los datos de la Organización Mundial de la Salud (OMS), la prevalencia global prácticamente se ha duplicado desde 1990, en donde el 7% de la población adulta padecía de diabetes, aproximadamente 200 millones de personas, y en el año 2022 la cifra se disparó a un alarmante 14%, lo que significa que 830 millones de personas padecen de esta enfermedad (OMS, 2024).

La Federación Internacional de Diabetes (IDF) reportó que 598 millones de personas adultas viven con diabetes, y se espera que, en el año 2050, ese número aumente hasta 853 millones de personas (IDF, s.f.). Esto se refleja también en la mortalidad, pues esta enfermedad causa complicaciones debilitantes como ceguera, insuficiencia renal, infartos o hasta amputaciones, y fue responsable de más de 2 millones de muertes en 2021. Cabe destacar que la hiperglucemia (niveles de glucosa altos en el organismo) asociada a la diabetes contribuye aproximadamente al 11% de las muertes por causas cardiovasculares, evidenciando la estrecha relación entre la diabetes y las enfermedades del corazón (OMS, 2024).

En España se reconoce que la diabetes es una de las enfermedades no transmisibles más frecuentes, pues afecta a casi 6 millones de personas en el país. Los datos recogidos por las “Encuestas Nacionales de Salud del Ministerio de Sanidad” reflejan una tasa de 7,51% (EPDATA, 2022). En la figura 1 se muestra el porcentaje de la población española con diabetes por grupos de edad en el año 1993, y en la figura 2 se observa este mismo gráfico para el año 2020. Se puede observar que el porcentaje total de la población aumentó en 3,42 puntos, y para mujeres y hombres de 75 años y más, este porcentaje aumentó en más de 10 puntos.




Figura 1. Porcentaje de la población española con diabetes por grupos de edad en 1993 (EPDATA, 2022).




Figura 2. Porcentaje de la población española con diabetes por grupos de edad en 2020 (EPDATA, 2022).

Por otro lado, los hábitos alimentarios poco saludables y el consecuente aumento de la obesidad están desencadenando una epidemia de enfermedades crónicas. Según lo dicho por la OMS, en 2022, una de cada ocho personas en el mundo era obesa, y la proporción de adultos con obesidad se ha más que duplicado desde 1990 (OMS, 2025).

El sobrepeso es un factor de riesgo clave para la diabetes tipo 2, enfermedades cardiovasculares y ciertos cánceres. Este es otro tipo de enfermedades que se destacan en el control de la glucosa como derivada, y es importante porque las enfermedades cardiovasculares son la principal causa de muerte mundial, causaron aproximadamente 19 millones de fallecimientos en 2021. Todas estas son enfermedades no transmisibles, las cuales se ven agravadas por una alimentación poco saludable, como puede ser rica en azúcares y grasas de baja calidad, pero deficiente en nutrientes (OMS, 2024). En suma, la combinación de dietas inadecuadas y factores de sanidad generales globales, han creado una urgente necesidad de estrategias eficaces de prevención y control.

En este contexto, la monitorización de la glucosa sanguínea y el control de los carbohidratos en la dieta se plantean como pilares fundamentales para prevenir y manejar las enfermedades relacionadas a la glucosa como las que se discutieron anteriormente. La monitorización es una técnica que se viene utilizando por pacientes con diabetes para regular los niveles de azúcar en sangre, pues permite ajustar tiempos en los tratamientos y tomar decisiones alimentarias, ayudando a mantener la glucemia dentro de rangos seguros. Los Centros para el Control y la Prevención de Enfermedades de Estados Unidos (*Center for Disease Control and Prevention*, CDC) destacan que la vigilancia del nivel de glucosa es la medida más importante para manejar la diabetes (CDC, s.f.).

Igualmente, una dieta equilibrada con especial atención a los carbohidratos es esencial para evitar picos hiperglucémicos perjudiciales. En la práctica clínica, se recomienda el conteo de los hidratos de carbono como estrategia para gestionar la dieta diabética: este método consiste en contabilizar los gramos de carbohidratos de cada comida y equilibrarlos con la dosis de insulina correspondiente, lo que ayuda a mantener la glucemia posprandial (después de consumir un alimento) bajo control de acuerdo con la *American Diabetes Association* (ADA, s.f.). En general, numerosas guías internacionales enfatizan que seguir una alimentación saludable, que es rica en fibra y con una ingesta moderada y medida de carbohidratos de absorción lenta, junto a otros hábitos saludables como el ejercicio, pueden ayudar a prevenir o retrasar la diabetes tipo 2, además de

mejorar el pronóstico de quienes ya la padecen. Por tanto, el control dietético y la monitorización metabólica constituyen intervenciones críticas para abordar tanto la diabetes como otras enfermedades crónicas relacionadas con la nutrición (OMS, 2024).

Sin embargo, existen diversas dificultades para mantener un recuento preciso y constante de los carbohidratos ingeridos pues puede llegar a ser notoriamente complejo. Incluso algunos profesionales expertos en el campo de la diabetes pueden tener problemas para un conteo riguroso de carbohidratos (MedTronic, 2022). Se ha demostrado que un conteo de carbohidratos preciso es crucial para poder gestionar la respuesta glucémica postprandial, en cambio, un conteo impreciso, especialmente subestimando o sobreestimando los carbohidratos, puede llevar a una respuesta de hiperglucemia (aumento en los niveles de glucosa en sangre) o hipoglucemia (decrecimiento en los niveles de glucosa en sangre) respectivamente (Deeb *et al.*, 2017).

En la práctica cotidiana, el conteo de carbohidratos puede ser propenso a errores humanos, y en general puede volverse fastidioso. Entre las principales barreras se incluye el olvido de registrar o compensar ciertos alimentos, la falta de conocimientos nutricionales o habilidades numéricas para estimar porciones, y errores al leer etiquetas nutricionales, que lleva a subregistros frecuentes de la ingesta real, pues la tendencia general es a subestimar la cantidad de carbohidratos que se consumen (Sulik *et al.* s.f.).

Estas imprecisiones no se limitan al registro manual, actualmente existen aplicaciones móviles de diario alimentario que facilitan el proceso, pero incluso en estas se han observado subestimaciones sistémicas que, en promedio, son de aproximadamente 6% menos de carbohidratos registrados frente a lo consumido (Gioia *et al.* 2023). Así, la variabilidad de los alimentos ya sea por diferencias en recetas, tamaños de porción o métodos de preparación, junto a los sesgos de reporte, hacen prácticamente inevitable cierto grado de error en el monitoreo dietético diario. Todo esto explica por qué el autocontrol de carbohidratos es percibido como un proceso difícil y frustrante, llevando a un registro incompleto o inexacto de la dieta y, en última instancia, pudiendo afectar negativamente el control glucémico (Chotwanvirat *et al.* 2021).

1.1. Modelos de aprendizaje automático como herramienta para afrontar el desafío de la monitorización continua

La integración de herramientas de inteligencia artificial junto al monitoreo continuo de glucosa ha permitido notables avances en el cuidado y prevención de estas enfermedades no transmisibles. Los modelos de aprendizaje automático ofrecen la capacidad de analizar grandes volúmenes de datos clínicos y de estilo de vida, descubriendo patrones complejos que escapan al análisis tradicional (IBM, 2021).

Uno de los artículos más famosos en el tema es el de Zeevi *et al.* en el que proponen una nutrición personalizada a través de la predicción de la respuesta glucémica postprandial (Zeevi *et al.* 2015), es decir, el planeamiento de la dieta alimentaria de cada individuo con la predicción de la respuesta glucémica que tendrá el individuo, buscando minimizar picos de glucosa. Este enfoque resulta interesante porque plantea la prevención del problema del registro a través de un planeamiento basado en datos e inteligencia artificial.

En general, el aprovechamiento de tecnologías basadas en datos permite profundizar en la relación entre la nutrición y las enfermedades, habilitando una nutrición de precisión que conlleva mejores estrategias de prevención y manejo de condiciones crónicas. En este sentido, la aplicación de modelos de *machine learning* (ML) para predecir la carga de carbohidratos de los alimentos de acuerdo con la respuesta glucémica individual representa una vía prometedora para optimizar el monitoreo dietético.

El presente trabajo se plantea en esta línea, explorando cómo los modelos de ML, a través del monitoreo de ingesta de carbohidratos automática, pueden contribuir a una gestión dietética más eficaz y, por ende, a la reducción del riesgo de diabetes y otras enfermedades asociadas a los malos hábitos alimentarios. Para ello se trabaja con el único conjunto de datos público del que se tiene conocimiento en la actualidad en cuanto al monitoreo continuo de glucosa de un grupo de sujetos de estudio, se presenta la metodología aplicada para conseguir predecir la carga de carbohidratos, y se plantea una aplicación a futuro para poder llevar la prevención de este tipo de enfermedades a un nivel superior.

Además, se analizan los diferentes eventos de ingesta de comida del conjunto de datos para determinar distintos perfiles de respuesta glucémica postprandial de los diferentes tipos de alimentos según sus nutrientes que permite la personalización de dietas según el tipo de respuesta que generan. Este enfoque permite utilizar tanto el aprendizaje supervisado, con las predicciones de carbohidratos, como el aprendizaje no supervisado, con la creación de perfiles de respuesta glucémica (*clustering*). De esta manera se obtiene una visión exploratoria y se aporta una función operativa, enfocadas en un enfoque de salud personalizada.

2. OBJETIVOS

2.1. Objetivo General

Desarrollar un modelo de Machine Learning para predecir carbohidratos ingeridos a partir de curvas de glucosa postprandial.

2.2. Objetivos Específicos

- Análisis de un conjunto de datos de monitoreo continuo de glucosa.
- Realizar limpieza, análisis exploratorio y extracción de métricas glucémicas.
- Integrar datos clínicos y del microbioma.
- Evaluar la utilidad predictiva de distintos modelos de predicción.
- Plantear aplicaciones para pacientes con diabetes.
- Crear y analizar perfiles de respuesta glucémica postprandial de los diferentes tipos de alimentos según sus nutrientes.

3. ESTADO DEL ARTE

3.1. Importancia de los carbohidratos y la dieta en el control glucémico

Los hidratos de carbono, también conocidos y referidos en adelante en este trabajo como carbohidratos, son indispensables en el consumo humano, pues proporcionan una de las principales fuentes de energía. Los carbohidratos simples de digestión rápida aportan glucosa, un sustrato energético fundamental para el cerebro, el sistema nervioso central y los glóbulos rojos, mientras que su almacenamiento posterior como glucógeno en el hígado y los músculos ayuda a regular el suministro de energía durante períodos de ayuno o de mayor actividad. El rendimiento energético de los carbohidratos digestibles, que suele ser de aproximadamente 3.75-4 kcal por gramo, es fundamental para satisfacer las demandas energéticas diarias del ser humano (Englyst, K. & Englyst, H., 2005).

Los carbohidratos son, en su explicación química, un grupo de moléculas compuestas principalmente de carbono, hidrógeno y oxígeno. Estos pueden estar presentes desde una forma simple (como la glucosa y la fructosa), hasta formas muy complejas conocidos como polisacáridos, por las unidades de monosacáridos que los conforman (su grado de polimerización). Su estructura química puede variar desde simple hasta compleja, y estas diferencias moleculares influyen en la digestión, absorción y los efectos metabólicos de ellos (Cummings *et al.* 1997).

Cuando los carbohidratos son ingeridos como alimento, el cuerpo los descompone en glucosa y los absorbe en el torrente sanguíneo, elevando así la concentración de azúcar en sangre, generando una respuesta glucémica tras alimento, conocido por el término postprandial. En general la alimentación es un pilar fundamental en el manejo de la glucemia y forma parte de la terapia médica nutricional recomendada para la diabetes (Katsumi, I., & Yabe, D., 2023). En particular, controlar la cantidad total de carbohidratos de la dieta y privilegiar fuentes de hidratos de carbono de calidad puede mejorar significativamente el control glucémico. Estudios comparativos indican que las dietas con menor proporción de carbohidratos producen descensos adicionales de la hemoglobina glucosilada (HbA1c) en el corto plazo, en comparación con dietas altas en carbohidratos,

una medida del promedio de los niveles de glucosa en sangre durante un periodo de 2 a 3 meses (Snorgaard *et al.* 2016).

Pero no existe un porcentaje fijo “ideal” de carbohidratos válido para todos los pacientes; las guías enfatizan la individualización de la dieta según las necesidades y objetivos de cada persona. Aun así, la evidencia muestra que reducir la cantidad total de carbohidratos suele contribuir a mejorar la glucemia, siempre dentro de un enfoque equilibrado que mantenga una nutrición adecuada. Esto cobra sentido al entender que más allá de la cantidad, la distribución y el tipo de carbohidratos en la dieta son igualmente importantes. Usualmente se aconseja la distribución de los carbohidratos en las distintas ingestas de alimentos del día, y optar por carbohidratos de bajo índice glucémico, que son de absorción lenta, pues producen elevaciones más suaves de glucemia (Katsumi, I., & Yabe, D., 2023).

3.2. Respuesta glucémica postprandial

Se denomina respuesta glucémica postprandial al cambio en los niveles de glucosa en sangre que ocurre tras la ingestión de alimentos, particularmente durante las primeras horas después de una comida. En individuos sanos, la glucemia típicamente se eleva de forma moderada después de comer y retorna a valores cercanos a los basales en unas 2 o 3 horas, gracias a la acción de la insulina. En personas con alteraciones del metabolismo de la glucosa, como la diabetes, la respuesta postprandial suele ser más pronunciada y prolongada, reflejando la dificultad del organismo para manejar la carga de carbohidratos ingerida (Dimitriadis *et al.* 2021).

Los carbohidratos son el macronutriente con mayor impacto directo sobre la glucemia tras las comidas. Los otros macronutrientes que se ven involucrados en la modulación de la respuesta glucémica postprandial son la proteína, la grasa y la fibra. Cada una cumple una función especial: las grasas retrasan el vaciado gástrico (Dimitriadis *et al.* 2021), lo que provoca una liberación más lenta de carbohidratos y reduce los picos de glucosa. La fibra ralentiza la digestión y absorción de carbohidratos, mientras las proteínas estimulan

a secreción de insulina y de hormonas intestinales (Bellisimo, N. & Akhavan, T., 2015). En la figura 3 se observan dos mediciones de glucosa, cada una representa un sensor de glucosa diferente; las marcas verdes en cada línea representan el inicio de un evento de ingesta de alimentos. Se aprecia que después de consumidos los alimentos, la glucosa aumenta en el gráfico y posteriormente vuelve a su estado basal.




Figura 3. Curva de glucosa pre y postprandial.

La hiperglucemia postprandial ocurre cuando la glucosa se ve aumentada niveles encima de lo normal después de las comidas, y es una característica importante para monitorizar en el control glucémico. En términos de objetivos, organizaciones como la American Diabetes Association recomiendan frecuentemente mantener la glucemia por debajo de ~180 mg/dL a las 1–2 horas post comida en pacientes diabéticos, aunque los rangos pueden individualizarse (ADA, s.f.).

La respuesta glucémica postprandial ha demostrado ser importante como un factor de riesgo en enfermedades. Una elevación excesiva de la glucosa tras la ingesta de alimentos se ha asociado con mayor riesgo de complicaciones macrovasculares: evidencias señalan que los “picos” hiperglucémicos posprandiales contribuyen al daño vascular y se vinculan con un incremento en la incidencia de enfermedad cardiovascular en pacientes con diabetes tipo 2. Lograr un mejor control de la glucemia postprandial se asocia con mayor reducción del riesgo cardiovascular, pues evita exposiciones repetidas

a picos de glucosa. En general, a medida que se optimiza el control glucémico general, afinar el control de las glucemias postprandiales se vuelve crucial para alcanzar la meta terapéutica y prevenir complicaciones (Vlachos *et al.* 2020).

3.3. Índice glucémico, carga glucémica y área incremental bajo la curva (iAUC)

El índice glucémico (IG) es un concepto desarrollado para clasificar los alimentos con carbohidratos según su potencial de elevar la glucosa en sangre. En términos prácticos, el IG asigna a cada alimento un valor numérico en una escala de 0 a 100, que indica la rapidez con la que aumenta la glucemia tras su consumo, en comparación con un alimento de referencia que usualmente es glucosa pura o pan blanco (pues su IG se define como 100) (MedlinePlus, s.f.).

Un alimento con IG alto (100 o próximo a 100) provoca una elevación rápida y pronunciada de la glucosa sanguínea, mientras que un alimento con IG bajo genera un alimento más lento y reducido. En la tabla 1 se pueden encontrar diferentes alimentos con su índice glucémico: el pan blanco industrial tipo molde tiene IG alto, mientras que la manzana o los cacahuates, que son alimentos ricos en fibra y con azúcares de absorción más lenta, presentan IG bajo. De acuerdo con el *Linus Pauling Institute* de la Universidad Estatal de Oregon (2016), los valores de índice glucémico suelen clasificarse como sigue:

- IG bajo: Valor menor o igual a 55
- IG moderado: Valor entre 56 y 69
- IG alto: Valor mayor o igual a 70

Alimento	IG
Manzana	35
Brócoli	15
Harina de arroz	95
Pan de baguette	72
Yogur líquido con azúcar	57
Queso mozzarella	27
Soja cocida	42
Cacahuetes	14
Atún al natural	0
Pechuga de pollo a la plancha	0
Cerveza rubia	66
Pan blanco industrial tipo molde	95

Tabla 1. Tabla con el índice glucémico de los alimentos (Clínica Universidad de Navarra, s.f.).

El IG refleja la calidad glucémica de los carbohidratos de un alimento, independientemente de la cantidad consumida. Los alimentos de bajo IG tienden a ayudar en el control glucémico al provocar menores picos de glucosa, por lo que se promueve su consumo en planes alimentarios para personas con diabetes o resistencia a la insulina. El consenso general es que el IG es una herramienta útil para orientar la elección de alimentos con impacto glucémico favorable, complementaria al conteo de carbohidratos tradicional (Luna *et al.* 2014).

Por su parte, la carga glucémica (CG) es un concepto relacionado que tiene en cuenta tanto la calidad de los carbohidratos (IG) como la cantidad de carbohidratos consumidos. Surge para solventar una limitación del IG: este índice compara alimentos en cantidades conocidas de carbohidratos, pero en la vida real las porciones consumidas varían. Así, la CG de una porción de alimento se calcula multiplicando el IG del alimento por la cantidad de carbohidratos (en gramos) de la porción, y dividiendo por 100 (Luna *et al.* 2014).

Este cálculo proporciona un valor que refleja la carga glucémica total que ese alimento aportará en una porción típica. Por ejemplo, una sandía tiene un IG alto (aproximadamente 72) porque su azúcar se absorbe rápido, pero en 100g de sandía hay pocos carbohidratos disponibles, su CG por porción moderada resulta relativamente baja (aproximadamente 5 por una rebanada estándar). En cambio, un alimento denso en carbohidratos como el arroz blanco tiene IG alto (~73) y además suele consumirse en porciones con muchos gramos de carbohidratos, dando como resultado una CG elevada (una taza de arroz cocido puede tener CG >30). En términos interpretativos, se suele considerar carga glucémica baja aquella inferior a 10 por porción, alta la superior a 20, quedando valores intermedios como CG moderada (aunque estos rangos son orientativos) (Linus Pauling Institute, 2016).

En resumen, la CG es un complemento útil al IG: mientras el segundo informa qué tan rápido eleva la glucosa un alimento, la CG indica cuánto eleva la glucosa la porción consumida. Integrar ambos conceptos permite afinar la planificación dietética para optimizar la respuesta glucémica postprandial. Una dieta con baja carga glucémica global implica que, además de escoger alimentos de IG bajo o medio, se controla el tamaño de las raciones de carbohidratos para que el impacto glucémico total de cada comida sea reducido (Linus Pauling Institute, 2016).

Finalmente, el término área incremental bajo la curva (iAUC) se refiere a una medida cuantitativa de la respuesta glucémica total tras la ingesta de un alimento o comidas. Es el área bajo la curva de concentraciones de glucosa en sangre por encima del nivel basal (es decir, el incremento de glucemia) a lo largo de un período específico posterior a la comida, típicamente 2 horas (Luna *et al.* 2014).

A diferencia del área total bajo la curva (AUC total) que incluiría toda el área desde el eje horizontal, el iAUC considera solo el incremento de glucosa generado por el alimento, descartando el nivel inicial. Esta metodología se desarrolló justamente para ajustar las diferencias individuales en glucemia basal: al restar la glucosa basal de las mediciones, se aísla el efecto de la comida en la elevación de la glucosa (Cheng *et al.* 2018). En la figura 4 se observa una gráfica de la medición de dos sensores de glucosa, con el área

incremental bajo la curva resaltada, para cada sensor en su respectivo color, para las dos horas posteriores al inicio de un evento de comida; en una línea punteada se señala el valor basal de glucosa, y las líneas son las lecturas de los sensores a través del tiempo.




Figura 4. Gráficos de área incremental bajo la curva (iAUC) para dos sensores de glucosa después de un evento de comida.

El iAUC es ampliamente utilizado en investigaciones nutricionales; por ejemplo, es la base para calcular el índice glucémico de los alimentos, ya que el IG se define a partir del área incremental que produce un alimento de prueba comparada con la del alimento de referencia. En ensayos de alimentos o formulaciones, el iAUC permite comparar de forma integrada cómo difieren las respuestas glucémicas: un iAUC menor indica que el alimento produjo una elevación global de glucosa más pequeña. El cálculo del iAUC usualmente se realiza mediante la regla del trapecoide a partir de mediciones seriadas de glucosa postprandial (Cheng *et al.* 2018).

Desde un punto de vista práctico, el iAUC es útil para evaluar el impacto glucémico total de distintos alimentos o comidas en contexto experimental. Sin embargo, en la práctica clínica diaria suele ser más común usar indicadores más simples (como el pico postprandial o la glucemia a 2 horas) dado que calcular áreas bajo la curva requiere múltiples mediciones. Pero, gracias a la creciente disponibilidad de monitores continuos de glucosa es cada vez más factible estimar áreas bajo la curva de manera ambulatoria,

lo que le brinda un papel mucho más relevante al iAUC en la valoración personalizada de la respuesta glucémica (Cheng *et al.* 2018).

En cualquier caso, entender el concepto de iAUC refuerza la idea de que no solo importa el valor máximo de glucosa alcanzado tras comer, sino la exposición total a la glucemia postprandial. Esta perspectiva integral es importante al evaluar el efecto de la dieta en el control glucémico, ya que dos alimentos podrían tener picos similares, pero uno mantener la glucosa elevada por más tiempo que el otro, resultando en un iAUC mayor y, por ende, en un mayor impacto glucémico global (Cheng *et al.* 2018).

Así, el IG, la CG y la iAUC son conceptos complementarios que ayudan a caracterizar la respuesta glucémica a los alimentos: el IG refleja la calidad de los hidratos (velocidad de impacto), la CG incorpora también la cantidad, y el iAUC ofrece una medida objetiva de la respuesta glucémica total provocada, todos ellos con el fin último de comprender y mejorar el control glucémico postprandial en la práctica clínica y la investigación (Cheng *et al.* 2018).

3.4. Monitorización continua de glucosa (CGM)

La monitorización continua de glucosa o *continuous glucose monitoring* (CGM) consiste en sensores subcutáneos que miden la concentración de glucosa en el líquido intersticial de forma frecuente y automática, proporcionando un perfil detallado de la glucemia a lo largo del tiempo. La diferencia con los medidores puntuales de glucosa en sangre, los sistemas CGM registran continuamente tendencias y respuestas glucémicas, como la respuesta glucémica postprandial, y lo hacen en tiempo real. Esta capacidad resulta valiosa no solo para el manejo diario de la diabetes, sino también para aplicaciones de investigación, como modelos de aprendizaje supervisado (Rodboard, D., 2016).

En la última década se han popularizado varios sistemas CGM, entre los cuales destacan los dispositivos FreeStyle Libre de Abbott y Dexcom G6 de Dexcom. Existen versiones “profesionales” (Pro) de estos sistemas diseñadas para uso clínico retrospectivo. A continuación, se describen dos sensores representativos del estado del arte: Abbott

FreeStyle Libre Pro y Dexcom G6 Pro, detallando su funcionamiento técnico, modo de uso, parámetros medidos y la naturaleza de los datos que proveen. Asimismo, se analiza cómo sus características de diseño influyen en la calidad, resolución temporal y continuidad de los datos utilizados en modelos predictivos de glucemia o ingesta.

3.4.1. Abbott FreeStyle Libre Pro

El FreeStyle Libre Pro de Abbott es un sistema profesional de monitorización continua de glucosa diseñado para registrar los niveles de glucosa de un paciente de forma continua durante hasta 14 días para su análisis retrospectivo por el clínico. Su funcionamiento se basa en un pequeño sensor circular que el personal sanitario aplica en la parte posterior del brazo del paciente mediante un aplicador específico. El sensor contiene un filamento de aproximadamente 5 mm que se inserta bajo la piel en el tejido subcutáneo, donde entra en contacto con el líquido intersticial y mide la glucosa por vía electroquímica. No requiere calibración mediante glucómetro (viene precalibrado de fábrica), eliminando la necesidad de punciones capilares de sangre. Una vez colocado, el dispositivo no necesita ninguna interacción por parte del paciente durante el periodo de monitorización: el sensor es resistente al agua y permanece adherido al brazo con un parche autoadhesivo hasta 14 días, registrando automáticamente la glucosa en intervalos regulares (Galindo *et al.* 2020).

El FreeStyle Libre Pro realiza mediciones de glucosa que se almacenan en una memoria interna del sensor, proporcionando un perfil glucémico amplio. Tras el periodo de tiempo, no mayor a 14 días, el sensor le es retirado al paciente y se utiliza un lector específico para escanear el sensor, vía NFC, para la descarga de los datos. Se destaca por una exactitud clínicamente aceptable, con un error medio relativo de entre 11 y 12% respecto a métodos de laboratorio. Su uso cegado, es decir, aquel en el que el paciente no visualiza las lecturas durante el estudio, evita alterar la conducta de alimentación o medicación, capturando la respuesta glucémica bajo condiciones habituales sin influencia del monitoreo (Galindo *et al.* 2020) En la figura 5 se observa el FreeStyle Libre Pro, siendo

el pequeño monitor el dispositivo para la lectura de datos, y el de la derecha el sensor de glucosa.



Figura 5. FreeStyle Libre Pro (Abbott Japan Co., Ltd.) (ResearchGate, s.f.).

3.4.2. Dexcom G6 Pro

La Dexcom G6 Pro es otro sistema de CGM para uso profesional, basado en la misma tecnología que el Dexcom G6 de uso personal. Consta de un sensor subcutáneo electroquímico insertado mediante un aplicador automático de un solo uso, y un pequeño transmisor que se acopla sobre el sensor para enviar los datos de glucosa de forma inalámbrica. En la figura 6 se observa el Dexcom G6 Pro, el sensor es la cápsula pequeña en la parte inferior, y el aplicador automático el aparato grande (Dexcom, s.f.).



Figura 6. Dexcom G6 Pro. (GEMCO Medical, s.f.)

El sensor se suele colocar en tejido subcutáneo del abdomen (o en el brazo, según aprobaciones locales) y tiene una vida útil de hasta 10 días antes de requerir recambio. Al igual que el Libre Pro, la Dexcom G6 Pro viene calibrada de fábrica y no necesita

calibraciones por parte del usuario; tras un período inicial de calentamiento (~2 horas) comienza a proporcionar lecturas de glucosa sin requerir ajustes con glucometría capilar. Tiene la capacidad de operar en modo cegado y modo en tiempo real (Dexcom, s.f.).

La memoria del transmisor y la sincronización periódica con el receptor aseguran la integridad de los datos incluso si hay pérdidas breves de conexión: el sistema puede almacenar en buffer varias horas de lecturas y luego trasmitirlas una vez restablecida la conexión. Presenta una elevada exactitud, el error medio relativo es 9% comparado con referencia de laboratorio (Dexcom, s.f.).

En resumen, ambos sensores representan el estado del arte en monitorización continua y aportan datos de calidad para analizar la respuesta glucémica a las comidas. Ambos sensores son de utilidad para un modelo que predice carbohidratos consumidos en base a la respuesta postprandial, pues el diseño profesional, usualmente con uso cegado, asegura que los datos reflejen la respuesta glucémica pura del organismo a la alimentación, sin influencias del comportamiento derivadas de la monitorización misma. Estas características hacen del Abbott FreeStyle Libre Pro y del Dexcom G6 Pro herramientas idóneas en la investigación actual que integra CGM con métodos de machine learning para estimar la ingesta de carbohidratos a partir de la glucemia y para otras aplicaciones que se han realizado, como predecir la respuesta glucémica postprandial.

3.5. Apps y métodos actuales para registro alimentario

Con el auge de los dispositivos móviles y el enfoque creciente en la salud digital, han surgido múltiples aplicaciones móviles diseñadas para facilitar el registro dietético de forma más rápida, accesible y estandarizada. Algunos de los ejemplos más reconocidos son *MyFitnessPal*, *Lifesum*, *MyNetDiary* y *MyRealFood*. Estas herramientas permiten a los usuarios registrar alimentos mediante búsqueda en bases de datos, escaneo de códigos de barras o incluso reconocimiento de imágenes, ofreciendo un cálculo automático de calorías y macronutrientes (Gioiga *et al.* 2023; Samad *et al.*, 2022).

La mayoría de estas aplicaciones calcula de forma instantánea el aporte nutricional (calorías, carbohidratos, proteínas, grasas, etc.) a partir de los datos ingresados, y varias ofrecen funciones de retroalimentación personalizada. Por ejemplo, muchas apps permiten fijar objetivos nutricionales diarios (como calorías o macronutrientes) adaptados a cada usuario en base a su información personal (peso, altura, objetivos de peso, nivel de actividad), e incluso el 64% de las aplicaciones evaluadas en un estudio requerían datos personales para calcular metas individualizadas. En esencia, estas apps intentan reducir la carga de los métodos tradicionales al automatizar cálculos nutricionales y facilitar el registro, haciendo el proceso más atractivo y sostenible (Gioiga *et al.* 2023).

3.5.1. Precisión del conteo de macronutrientes y errores sistemáticos

A pesar de las ventajas que ofrecen las apps de registro alimentario, las investigaciones señalan que persisten errores sistemáticos en las estimaciones dietéticas obtenidas a través de estas herramientas. En particular, se ha observado una tendencia a subestimar la cantidad de alimentos consumidos y, por ende, los nutrientes registrados. Por ejemplo, Gioia *et al.* (2023) evaluaron múltiples aplicaciones de dieta y hallaron que, comparadas con un método de referencia profesional (el software NDSR, considerado *gold standard*), las apps subestimaron en promedio alrededor de un 6% el contenido de carbohidratos de la dieta de los usuarios.

Esta discrepancia se reportó también en otros macronutrientes, en el estudio hecho por Zhang *et al.* (2021) concluyeron que los registros dietéticos móviles tienden a subestimar sistemáticamente la ingesta de carbohidratos, proteínas y grasas totales, en comparación con métodos tradicionales rigurosos. Estas diferencias sugieren la presencia de errores sistemáticos inherentes al automonitoreo dietético digital. Si bien en muchos casos las discrepancias absolutas pueden parecer modestas, su efecto acumulativo es relevante, especialmente en contextos clínicos donde la precisión nutricional es crítica.

3.5.2. Fuentes de error en el registro dietético con apps

Los errores en el conteo de nutrientes al usar diarios dietéticos provienen de diversas fuentes como la estimación del tamaño de las porciones consumidas. Muchos usuarios tienen dificultades para juzgar de forma precisa la cantidad de alimentos que ingieren (por ejemplo, cuántos gramos de pasta hay en su plato), lo que conlleva errores al ingresar los datos. En secciones anteriores, se determinó que la cuantificación de porciones es un punto crítico: subestimar o sobreestimar las raciones impacta directamente en la exactitud del conteo de carbohidratos y otros nutrientes (Evenepoel *et al.* 2020).

También es importante destacar la fatiga de la automonitoreo continua, pues de acuerdo a la encuesta realizada por Evenepoel *et al.* (2020), aunque el 80% de los participantes consideró fácil de usar una popular app de conteo calórico, solo 20% planeaba seguir usándola a largo plazo debido a frustraciones con la selección exacta de alimentos en la base de datos y la dificultad para estimar correctamente las porciones, sumado al tiempo que toma registrar todo (Evenepoel *et al.* 2020).

Otra fuente importante de error es la variabilidad entre recetas, preparaciones o productos comerciales. Los datos nutricionales en las bases de datos de las apps suelen basarse en promedios o en productos estándar; sin embargo, en la realidad, un mismo platillo puede prepararse con ingredientes y técnicas distintas que alteran su contenido nutricional. Por ejemplo, la cantidad de carbohidratos en una porción de *lasagna* casera puede variar según la receta (tipo de pasta, presencia de vegetales, etc.), y distintos fabricantes de un mismo alimento (como pan integral) reportan contenidos de fibra y carbohidratos ligeramente diferentes. Esta variabilidad natural puede provocar disparidades entre lo consumido y lo registrado, es decir, las aplicaciones no siempre reflejan con exactitud la composición específica del alimento que ingirió el usuario (Naska *et al.* 2017).

Adicionalmente, persisten los sesgos de reporte propios del comportamiento humano, por ejemplo, un usuario de apps podría olvidar registrar algún ingrediente o comida ya sea por descuido o prisa, o incluso omitir intencionalmente ciertos consumos. Este caso

suele relacionarse con factores psicológicos o sociales: por ejemplo, hay evidencia de que algunas personas tienden a subreportar alimentos percibidos como poco saludables o socialmente indeseables (snacks hipercalóricos, postres, cantidades extras). En el contexto de las apps, aunque la interfaz facilita la anotación, la participación activa del usuario sigue siendo imprescindible y está sujeta a errores voluntarios o involuntarios. Todo ello se traduce en que los datos recopilados pueden sesgarse hacia un consumo "ideal" o esperado, más que reflejar fielmente la ingesta real (Naska *et al.* 2017).

El reconocimiento de estas fuentes de error es fundamental para el planteamiento de desarrollos tecnológicos que intenten mitigarlas, siempre tomando en cuenta que ningún sistema es infalible. Actualmente los sistemas que más se están explorando son el uso de redes neuronales convolucionales para el reconocimiento automático de los alimentos a partir de una foto, calculando el tamaño de la porción, estimación de los nutrientes y calorías. En la revisión hecha por Yamamoto *et al.* (2024) se concluyó que las aplicaciones han logrado avances importantes en la clasificación de alimentos con alta precisión, sin embargo, todavía existen limitaciones cuando se trata de estimar porciones, reconocer platos complejos o comidas hechas en casa, debido a la variabilidad visual de los alimentos. Además, hay una falta de estandarización en los métodos usados y escasez de estudios que validen estas tecnologías en entornos reales.

3.6. Modelos de machine learning en salud metabólica

El uso de modelos de aprendizaje automático en la salud metabólica ha crecido exponencialmente, aplicándose tanto en enfoques supervisados, la predicción, como no supervisados, en la detección de patrones, con datos de glucosa. En el ámbito supervisado, múltiples estudios han entrenado modelos como *random forest*, *support vector machine* y redes neuronales profundas, para predecir la glucemia futura a corto plazo utilizando series de CGM. Por ejemplo, se ha demostrado que modelos basados en *deep learning* (redes LSTM, etc.) pueden anticipar los niveles de glucosa a 15 o 60 minutos con una precisión notable usando únicamente las tendencias recientes del CGM (van Doorn *et al.* 2021).

Estas predicciones de glucosa “a futuro” son útiles para alertar al paciente o ajustar dosis de insulina de forma proactiva, y han sido validadas en poblaciones con diabetes tipo 1, tipo 2 e incluso en individuos con prediabetes. En general, las técnicas de ML han superado a los métodos tradicionales en la capacidad de capturar la dinámica no lineal de la glucemia bajo distintas condiciones (comidas, ejercicio, insulina), mejorando la seguridad de sistemas como las bombas de insulina de lazo cerrado (van Doorn *et al.* 2021).

En el aspecto del aprendizaje no supervisado, el ML se ha utilizado para extraer patrones ocultos en los datos glucémicos continuos. Algoritmos de clustering y reducciones dimensionales han permitido identificar distintos perfiles de variabilidad glucémica a partir de datos CGM, lo cual ayuda a clasificar a pacientes según sus patrones metabólicos. Por ejemplo, han conseguido extraer automáticamente patrones de fluctuación de glucosa (“*time in patterns*”) que proporcionan una visión más rica del perfil glucémico de cada paciente, más allá de métricas agregadas convencionales. Estos análisis han revelado que existen subgrupos de individuos con dinámicas de glucosa similares (por ejemplo, patrones de picos matutinos vs. patrones estables), lo cual puede orientar intervenciones personalizadas (Chan *et al.*, 2023). En general, ya sea para predecir valores de glucosa o para descubrir patrones y subtipos metabólicos, el aprendizaje automático se ha convertido en una herramienta clave para analizar datos de CGM en investigaciones recientes.

3.7. Predicciones en la ingesta alimentaria y macronutrientes

Han surgido sistemas de recomendación inteligentes enfocados en la nutrición personalizada que emplean técnicas de filtrado de información y ML para sugerir alimentos adaptados a las necesidades y preferencias del usuario, enfocado en la mejora de la salud. En el caso de pacientes con diabetes, se han diseñado recomendadores de comidas que ofrecen opciones alimentarias personalizadas con conocimiento nutricional, buscando mejorar el control glucémico (Yera *et al.* 2023).

Un hito importante en el campo fue el trabajo de Zeevi *et al.* (2015), que demostró la posibilidad de predecir la respuesta glucémica individual a distintos alimentos utilizando un modelo de ML entrenado con datos clínicos, dietéticos y del microbioma personal. En este estudio pionero, cada participante llevaba un CGM y registraba sus comidas; con esos datos, el algoritmo aprendió a predecir la elevación de glucosa que provocaría un alimento específico en cada individuo. Los resultados evidenciaron una gran variabilidad interpersonal en las respuestas postprandiales y mostraron que al integrar características personales (p. ej., perfil metabólico y microbioma) se lograban predicciones más precisas que las basadas solo en índices glucémicos tradicionales.

En paralelo, han surgido investigaciones recientes que exploran técnicas para inferir automáticamente la ingesta de alimentos utilizando datos fisiológicos y herramientas de ML. Tal es el estudio de Zheng *et al.* (2019) que detecta comidas automáticamente utilizando CGM, insulina y ritmo cardíaco, el cual muestra ser preciso y rápido, además discute la aplicación de algoritmos como este para mejorar el dosaje de insulina en un páncreas artificial o para crear recordatorios en caso de olvidar aplicar la dosis.

Finalmente, algunos estudios se han dedicado a identificar los nutrientes consumidos por una persona utilizando los datos de su glucosa. Un ejemplo es el de Das *et al.* (2024) quienes utilizan un modelo de ML que predice una variable específicamente a partir de los datos de glucosa; esta variable “representa” el efecto combinado de todos los nutrientes en la glucosa. Para esto, utilizan datos previos sobre combinaciones típicas de alimentos. Sus principales limitaciones son la generalización de comidas y la dependencia de la variable latente, pues esta no es directamente interpretable. A pesar de que desarrollaron un modelo metabólico inverso para la variable, es complejo y depende de muchas suposiciones fisiológicas.

Otro caso es el estudio de Huo *et al.* (2019) que, en el mismo contexto, utilizaron los datos de glucosa para identificar los patrones de acuerdo con una red neuronal. La intención de este proyecto es el aprovechamiento de la red neuronal de combinar las variables de macronutrientes como proteína, grasa y carbohidratos para tener una mejor

predicción, sin embargo, no toman en cuenta un nutriente muy importante para la respuesta glucémica postprandial, la fibra.

3.8. Aplicaciones clínicas y tecnológicas

Muchos de los avances discutidos hasta ahora en este trabajo escrito se están trasladando a aplicaciones clínicas y herramientas tecnológicas de uso real. Un ejemplo destacado son las aplicaciones móviles de salud digital que integran datos de CGM con algoritmos inteligentes para guiar al usuario en sus decisiones de estilo de vida. En un estudio con más de 2 mil usuarios, se empleó un programa remoto con CGM y *wearables* que proporcionaba recomendaciones diarias personalizadas sobre alimentación y actividad física, basado en las pautas glucémicas individuales de cada participante. Mediante la app, los usuarios recibían *feedback* de sus patrones de glucosa superpuestos con sus registros de comidas y ejercicio, además de consejos dietéticos adaptados a sus preferencias y meta (Zahedani *et al.* 2023)

En el ámbito de la diabetes tipo 1, recientemente se validó un sistema de infusión de insulina totalmente automatizado, que por medio de una red neuronal busca detectar comidas no anunciadas y estimar su tamaño en carbohidratos, ajustando la dosis de insulina en consecuencia. En un ensayo clínico cruzado, este “páncreas artificial robusto” (RAP) identificó aproximadamente 83% de las comidas sin que el usuario ingresara datos, con un tiempo promedio de detección de entre 26 minutos tras el inicio de la ingesta. Aunque el algoritmo no mejoró significativamente el iAUC glucémico respecto a un sistema convencional, sí redujo el tiempo en hiperglucemia (>180 mg/dL) en aproximadamente 10% y mostró tendencia a aumentar el tiempo en rango óptimo (Mosquera-Lopez *et al.*, 2023).

Esta innovación tecnológica refleja una tendencia hacia dispositivos inteligentes (bombas de insulina, monitores CGM con algoritmos embebidos) que asisten o automatizan decisiones terapéuticas basadas en la predicción de eventos metabólicos. Aunque son estudios iniciales, respaldan la viabilidad clínica de integrar estos modelos en el manejo

diario: bien sea a través de apps de nutrición, plataformas de telemedicina o dispositivos médicos, la inteligencia artificial está comenzando a complementar las estrategias tradicionales de control metabólico.

3.9. La necesidad de soluciones automáticas sin registro manual

Dada la carga y las limitaciones de los registros dietéticos manuales ya sean físicos (hoja y papel) o digitales, como los que se han discutido, existe un imperativo claro de desarrollar métodos automáticos que infieran la ingesta alimentaria, y específicamente los nutrientes consumidos, sin requerir que el usuario anote todo lo que come. Registrar alimentos y carbohidratos en un diario es engorroso y propenso a errores humanos, pues muchas personas tienden a subestimar o sobrestimar lo que consumen en cuanto a contenido de carbohidratos, incluso tras entrenamiento nutricional (Deeb *et al.*, 2017).

Además de los estudios mencionados en apartados anteriores, Amorim *et al.* (2024) describen como en estudios en adolescentes, solo aproximadamente el 42% de las estimaciones de carbohidratos de una comida caen dentro de ± 10 g del valor real, lo que evidencia la imprecisión para los registros, y por consiguiente para establecer valores claros en respuesta glucémica postprandial y tener un conteo verdaderamente claro, por lo que un modelo de predicción que automatice este registro basado en la respuesta glucémica, es una estrategia adecuada.

Actualmente los sistemas que han intentado cubrir esta necesidad no son perfectos, algunos modelos pueden predecir variables de nutrientes para alimentos según la glucosa, pero no incluyen otros factores individuales como microbioma, nivel de estrés, sueño o ejercicio, que también afectan la respuesta glucémica, y por lo tanto están limitados a cierta población con características metabólicas similares. Existe el trabajo realizado por Daniels *et al.* (2023) en el que desarrollaron una red neuronal que detecta las comidas y estima su tamaño en gramos de carbohidratos. Probando en simulaciones *in silico* (simuladas por computador) de adultos con diabetes tipo 1, su algoritmo logró identificar eventos alimentarios con alta precisión y estimar la ingesta de carbohidratos

con un error promedio de aproximadamente 18g, y en torno al 80% de sus estimaciones cayeron dentro de $\pm 25g$ del valor real, aunque existió una ligera tendencia a la sobrestimación.

Entre los distintos modelos que se han analizado, se ha demostrado que es posible identificar patrones glucémicos característicos de una ingesta y derivar de ellos una estimación cuantitativa de carbohidratos, aunque con las limitaciones antes mencionadas, y otras más, pues la predicción de carbohidratos es modesta, típicamente con coeficientes de determinación R^2 en el rango bajo (0.2 a 0.4) en las evaluaciones reportadas. En el trabajo de Daniels *et al.* (2023) informan una dispersión considerable en la correlación entre el tamaño de la comida real y el estimado. También en otro trabajo mencionado anteriormente de Mosquera-Lopez *et al.* (2023) señalaron que su modelo no podía distinguir perfectamente el impacto glucémico de comidas de distintos tamaños.

Esto es entendible por los diversos factores inherentes que limitan la máxima precisión posible de las estimaciones automáticas. Además, Daniels *et al.* (2023) señalan que la estimación aproximada de carbohidratos fue suficiente para mejorar el tiempo en rango glucémico al integrarse a un páncreas artificial. Del mismo modo, Mosquera-Lopez *et al.* (2023) mostraron que un sistema de control automático “sin anuncio de comidas” puede atenuar la hiperglucemia posprandial casi tanto como cuando el paciente informa los carbohidratos manualmente.

Finalmente, los modelos creados hasta la fecha han significado una mejora sustancial en la automatización del registro nutrimental de alimentos con los datos de la respuesta glucémica postprandial, aún no se dispone de un modelo lo suficientemente robusto, preciso y generalizable como para ser implementado de forma fiable en contextos clínicos o aplicaciones a gran escala. La mayoría de los enfoques actuales se basan únicamente en los datos de glucosa en tiempo real, sin integrar de manera sistemática otros factores fisiológicos relevantes que modulan la respuesta postprandial, como el índice de masa corporal, el nivel de actividad física, el sueño, el estrés, el perfil lipídico, el estado de insulina basal o incluso características más complejas como el microbioma intestinal.

La incorporación de estos elementos, combinando información de bajo y alto nivel fisiológico, podría permitir una estimación más precisa de los carbohidratos ingeridos, adaptada a las características individuales de cada sujeto. Por tanto, existe una necesidad manifiesta de modelos que integren esta multidimensionalidad biológica y contextual, capaces de captar la complejidad de la respuesta glucémica humana y traducirla en estimaciones más exactas y personalizadas de la ingesta de nutrientes, particularmente de carbohidratos.

El desarrollo de este tipo de aproximaciones, basadas en aprendizaje supervisado y alimentadas por variables fisiológicas integradas con métricas dinámicas como la iAUC, representa un camino prometedor hacia sistemas de predicción más precisos, automatizados y escalables, con aplicaciones directas en la nutrición personalizada y el control metabólico.

4. METODOLOGÍA

Este trabajo aborda el problema descrito en la sección de estado del arte, en la cual se desarrolla el por qué del problema de estimar la cantidad de carbohidratos ingeridos por una persona a partir de la respuesta glucémica postprandial, así como de otros datos fisiológicos más “complejos” y específicos que son de especial interés como el microbioma intestinal. A diferencia de enfoques tradicionales que predicen la respuesta glucémica a partir del contenido nutricional conocido de los alimentos, este estudio adopta un enfoque inverso: dado un conjunto de variables fisiológicas medidas durante el periodo postprandial, se busca inferir los macronutrientes consumidos, con especial atención en los carbohidratos pues estos son los macronutrientes contenidos en alimentos que mayor efecto tienen en la glucemia.

Para ello, se utilizó un conjunto de datos multidimensional que combina información glucémica de dos sensores distintos, variables fisiológicas (ritmo cardíaco, gasto energético, METs), antropométricas, clínicas, del microbioma, e información contextual asociada a cada evento de comida. A partir de estas señales, se construyó un pipeline de procesamiento que permite identificar eventos postprandiales válidos, calcular métricas clave de la curva de glucosa, y entrenar modelos de aprendizaje automático que estiman la cantidad de carbohidratos ingeridos.

Este enfoque tiene el potencial de facilitar la monitorización nutricional de forma pasiva y personalizada, al proporcionar estimaciones automáticas del contenido de las comidas a partir de datos fisiológicos ya disponibles, lo cual podría aplicarse en contextos como el manejo de la diabetes, la nutrición personalizada o el desarrollo de sistemas inteligentes de salud.

4.1. Conjunto de datos

Gutierrez-Osuna *et al.* (2025) desarrollaron un conjunto de datos científico para la investigación en nutrición personalizada y para monitoreo dietético. De acuerdo con lo descrito en el artículo en el que lo presentan, es el único *dataset* de mediciones de

glucosa público que existe. Para entender por completo cómo está conformado, es importante explicar su proceso de creación, tal como lo explican en su artículo.

El *dataset* fue construido a partir de datos recolectados de 45 personas adultas voluntarias de entre 18 y 69 años, con un índice de masa corporal (IMC) entre 21 y $46\text{kg}/\text{m}^2$. De acuerdo con sus niveles de HbA1c, los participantes se clasificaron como sigue:

- 15 personas sanas ($\text{HbA1c} < 5.7\%$)
- 16 personas con prediabetes ($5.7\% \leq \text{HbA1c} \leq 6.4\%$)
- 14 con diabetes tipo 2 ($\text{HbA1c} > 6.4\%$)

Todas ellas fueron reclutadas entre 2021 y 2024 por el Samsun Diabetes Research Institute en California, Estados Unidos.

Cada participante llevó puestos durante 10 días dos sensores de glucosa continua: Dexcom G6 Pro y FreeStyle Libre Pro, en paralelo con un Fitbit Sense para el registro de la actividad física. Para llevar el registro de sus alimentos, las comidas fueron registradas mediante la aplicación *MyFitnessPal*, acompañadas de fotos tomadas con *WhatsApp*. El diseño alimentario incluye desayunos controlados con batidos proteicos de composición variable, almuerzos de restaurantes con perfiles nutricionales conocidos, y cenas libres elegidas por los participantes. Además, para minimizar el solapamiento de respuestas glucémicas se impuso un ayuno de mínimo 3 horas entre comidas principales.

Este conjunto de datos demostró ser muy completo al recoger heces el primer día para analizar el microbioma usando kits de *Viome Life Sciences*. Además, los sensores de glucosa fueron colocados en modo cegado para garantizar la mayor fidelidad a la realidad posible. De esta manera el *dataset* incluye mediciones de sensores de glucosa, fotografías de comidas antes y después de su consumo, el registro nutricional de los macronutrientes y contenido calórico, la actividad física, medidas antropométricas, parámetros clínicos, perfil del microbioma intestinal y datos demográficos anonimizados.

Se eligió trabajar con este conjunto de datos por su completitud en cuanto a factores que se discutieron, suelen faltar en el entrenamiento de otros modelos de predicción de

carbohidratos, como el microbioma, factores demográficos y otros parámetros clínicos. También se consideró que el contexto brindado en el conjunto de datos como las fotografías de los alimentos y otras variables como la hora del consumo pueden ser factores muy beneficiosos para el análisis. Además de ser el único conjunto de datos público que incorpora mediciones continuas de glucosa.

Sin embargo, también se debe tomar en cuenta las diversas limitaciones que este conjunto de datos presenta, pues al tener los datos de únicamente 45 personas, no se puede considerar una cantidad de personas representativa. Además, las mediciones realizadas durante los 10 días a cada sujeto llevaron a tener registro glucémico de no más de 1.700 eventos de comida, lo cual representa un volumen de datos pequeño para el entrenamiento de modelos, aunque hay modelos muy robustos que pueden encontrar patrones en este tipo de volúmenes de datos, se considera un factor a considerar.

4.2. Procesamiento de datos

El procesamiento de datos constituyó una etapa crítica para garantizar la calidad y fiabilidad del análisis posterior. El conjunto de datos original se compone por más de 687.580 registros minuto a minuto y 18 variables por observación. Además, existen 3 conjuntos de datos complementarios:

- “bio.csv”: Incluye datos demográficos, antropométricos y analíticas de sangre, obtenidas el primer día del estudio, tales como niveles de glucosa en ayuno, insulina, HbA1c, colesterol total, HDL, LDL, VLDL y triglicéridos.
- “microbes.csv”: Contiene un vector binario para cada participante que indica la presencia (1) o ausencia (0) de 1,979 especies bacterianas identificadas en muestras de microbioma intestinal.
- “gut_health_test.csv”: Proporciona 22 *scores* ordinales relacionados con el estado funcional del sistema digestivo de cada sujeto (por ejemplo, salud intestinal general, eficiencia digestiva, actividad inflamatoria), codificados como *Good* (3), *Average* (2) o *Not Optimal* (1).

Como se puede apreciar, el procesamiento de datos representó un reto porque representó el tratamiento de 4 conjuntos de datos cuyos registros estaban conectados por pertenecer a un paciente o sujeto de estudio.

Se realizaron múltiples imputaciones de valores nulos de acuerdo con el problema en cuestión, si se tratase de una variable categórica, se imputaba con la moda, a menos que fuera una variable a la cual se le reconocía una correlación a otras variables, las cuales fueron imputadas por medio del algoritmo *KNNImputer* que permitió tomar un promedio de los vecinos más cercanos para la imputación de valores. En este punto no se imputaron variables numéricas.

También se hizo tratamiento de *outliers* para las variables fisiológicas y clínicas, contemplando siempre mantener una variabilidad fisiológicamente posible pues, aunque los datos fueron medidos en laboratorio, el análisis del rango intercuartílico demostró la presencia de *outliers* muy extremos, lo cual podría deberse a errores de registro.

4.2.1. Tratamiento del conjunto de datos “*microbes*”

El procesamiento del conjunto de datos “*microbes*” fue uno de los más complicados de realizar, principalmente porque contemplar la implementación del conjunto como variables para la predicción de carbohidratos que componen cada alimento, agregar 1980 columnas al entrenamiento y predicción hubiera podido representar ruido para el aprendizaje del modelo en lugar de patrones generalizables por la alta dimensionalidad. Además de que, entre 1980 columnas seguramente hay mucha información redundante o poco informativa.

Por estos motivos, después de la imputación de valores nulos, se hizo análisis de componentes principales (*PCA*) por medio del cual, como se muestra en la figura 6, se descubrió que por medio de 3 componentes principales se logra explicar cerca del 50% de la variabilidad del conjunto de datos entero, de esta forma, pudiendo agregar esos 3 componentes principales como 3 columnas del entrenamiento del modelo, y no 1980.




Figura 6. Varianza explicada por cada componente principal del análisis de componentes principales.

4.2.2. Tratamiento del conjunto de datos “meals”

El conjunto de datos “*meals*” fue creado a partir de la información del *dataset* principal. Este conjunto de datos cuenta con la “facilidad” de poder enfocarse directamente en la predicción de carbohidratos, pues los inicios de los eventos de comida fueron registrados por los sujetos del estudio, ya que estos debían registrar una foto de su comida antes y después del consumo, y esto estuvo registrado en el *dataset* principal junto a los macronutrientes en una misma fila. Entonces, cuando sucede un inicio de evento de comida, es decir, cuando un sujeto comenzó a ingerir alimento, en el *dataset* se ve reflejado porque algunas filas que constantemente son valores nulos, como la columna “carbs” que registra los carbohidratos de cada comida, en ese momento específico, marcado por la variable de tiempo “*timestamp*”, no es un nulo, pues lleva la información de la comida.

De esta forma se puede obtener un conjunto de datos separado que se procesó para entender cómo estaba conformada cada comida y poder hacer el tratamiento de datos óptimo para estos registros. Entre la limpieza de datos realizada se analizaron las

variables de macronutrientes de los alimentos, encontrando *outliers* y registros extraños los cuales se analizaron gracias al registro fotográfico que presentaban, investigación, y al análisis de otras variables, para determinar su tratamiento oportuno.

4.3. Extracción de eventos de comida

Como se planteó en la sección de respuesta glucémica postprandial, esta se calcula dos horas después de que comienza el evento de comida, es decir, del momento en que comienza el sujeto a ingerir alimentos. Conociendo esto, se realizó un proceso riguroso para identificar, corregir y validar eventos de ingesta alimentaria mal registrados en el conjunto de datos, con el objetivo de garantizar la integridad temporal y fisiológica de los eventos postprandiales.

Mientras se procesaban los datos se encontró con una limitante importante, y es que muchos de los eventos de comida, estaban registrados mal en el tiempo, al menos fisiológicamente pues, como se muestra en la figura 7, el inicio del evento era en un pico de glucosa, lo que sugiere que el registro se realizó tarde, tiempo después de iniciada la ingesta.




Figura 7. Curva de glucosa postprandial. En esta curva de glucosa el inicio de la comida está en el máximo local de las mediciones de glucosa o muy cercano a él.

Por este motivo se desarrolló una función para detectar si un evento de comida se registró en el momento del pico glucémico y, en caso afirmativo, se corrigió retrocediendo hasta el último mínimo local de glucosa utilizando técnicas de detección de picos invertidos, trasladando entonces los datos del evento de comida al *timestamp* encontrado con la función. A continuación, se validó la efectividad de las correcciones aplicadas mediante el cálculo del área incremental bajo la curva (iAUC) y el pico glucémico en las ventanas postprandiales originales y corregidas. Este paso permite evaluar si la nueva asignación temporal representaba mejor la dinámica fisiológica esperada tras la ingesta de alimentos.

El sistema considera válida una reasignación solo si el nuevo punto de inicio del evento se encuentra dentro de una ventana de cinco minutos de un *timestamp* existente y no interfiere con otro evento ya registrado, lo cual fortalece la coherencia temporal del conjunto de datos. De esta forma se lograron rescatar 89 registros que estaban mal registrados.

Una vez corregidos los *timestamps*, se filtran los eventos de comida para conservar únicamente aquellos que cumplen estrictamente con la condición de no estar precedidos por otras comidas en la hora anterior ni seguidos por otra ingesta en las dos horas posteriores. De este modo, se aíslan eventos postprandiales sin interferencias, adecuados para el análisis glucémico. Posteriormente, se construyen ventanas de dos horas posteriores a cada evento válido, y se etiquetan todas las mediciones contenidas en dichas ventanas con el *timestamp* del inicio del evento correspondiente. Este proceso permite analizar y comparar la evolución de la glucosa tras la ingesta de alimentos de forma estructurada y coherente.

Finalmente, se crearon tres subconjuntos del conjunto de datos para diferentes propósitos analíticos: uno con eventos completos que contienen datos simultáneos tanto de Dexcom como de Libre (*glucose_both_df*), otro con eventos completos solo del sensor Libre (*glucose_libre_only_df*), y un tercero con eventos con datos faltantes para documentar su exclusión. Esta separación permitió una caracterización detallada de los

perfiles glucémicos bajo diferentes condiciones de disponibilidad de datos, permitiendo también una mejor aplicación para la creación de modelos.

Los resultados que se obtuvieron se muestran en la figura 8, donde se muestra un ejemplo de una curva de glucosa que cumplió las validaciones anteriores, y se refleja en la forma de su pico que, en paralelo, es consistente con el tipo de alimento que se observa en la fotografía del registro, que es un helado. Se observan los picos máximos de la curva de glucosa aproximadamente una hora después del comienzo del evento.




Figura 8. Curva de glucosa postprandial validada junto a la fotografía registrada para ese evento de ingesta de alimentos.

4.4. Cálculos de métricas glucémicas

Se generaron métricas descriptivas de la respuesta glucémica y fisiológica tras eventos de ingesta de comida, considerando los dos sensores de glucosa (Dexcom y Libre), y para un conjunto de datos únicamente de registros provenientes del sensor Libre. Primero, se realizaron imputaciones para variables fisiológicas relevantes dentro de ventanas de dos horas posteriores a cada evento alimenticio registrado. Las variables

imputadas fueron *calories_(activity)*, *hr* (frecuencia cardíaca), y *mets* (equivalentes metabólicos).

La imputación se efectuó siguiendo un enfoque jerárquico: inicialmente, se aplicó interpolación lineal dentro de las ventanas postprandiales específicas por paciente y evento; posteriormente, se utilizaron valores promedio por paciente para completar los valores faltantes restantes; finalmente, cualquier valor aún nulo fue reemplazado por el promedio general de la variable correspondiente. Este procedimiento se aplicó por separado a los datasets *glucose_both_df* y *glucose_libre_only_df*.

Posteriormente, se calcularon métricas postprandiales para cada evento identificado, considerando una ventana de análisis de dos horas para ambos datasets. Estas métricas incluyeron:

- El área incremental bajo la curva (iAUC) para glucosa medida tanto por el sensor Libre como por el sensor Dexcom.
- El valor pico alcanzado por la glucosa (*peak_value*), el cambio absoluto desde el valor basal (*delta*) y el tiempo hasta alcanzar dicho pico (*time_to_peak*).
- La variabilidad de la glucosa postprandial, medida mediante la desviación estándar durante la ventana de análisis.
- Una métrica adicional de iAUC temprana (*early_iauc*), correspondiente a los primeros 30 minutos posteriores a la ingesta.
- Promedios de calorías gastadas por actividad, frecuencia cardíaca y METs durante la ventana de observación postprandial.

Todos estos valores fueron consolidados en dos nuevos *DataFrames*: *metrics_both_df*, correspondiente a eventos con datos combinados de sensores, y *metrics_libre_df*, correspondiente a eventos donde únicamente se disponía de información del sensor Libre. Esta separación permitió una evaluación diferenciada de la respuesta glucémica según la disponibilidad de los sensores, facilitando el análisis comparativo y la posterior implementación de modelos predictivos ajustados a diferentes configuraciones de datos. Se unieron todos los conjuntos de datos provistos y preprocesados para condensar en

un solo *DataFrame* toda la información de la que se dispone, y que sería útil para el entrenamiento de modelos.

Además, como parte del *feature engineering* se hizo una ampliación y refinamiento de los conjuntos de datos derivados del análisis postprandial incorporando variables transformadas, compuestas y normalizadas con el fin de facilitar análisis posteriores más robustos y comparables entre pacientes, eventos y métricas fisiológicas.

Primero, se realizó una transformación cíclica de la variable *meal_time*, extrayendo la hora del evento alimenticio (*meal_time_hour*) y transformándola en dos componentes trigonométricos (sin y cos). Esta transformación se basó en la naturaleza periódica de las horas del día y tiene como objetivo preservar la continuidad circular de la variable temporal, permitiendo su inclusión como input en modelos estadísticos o de aprendizaje automático sin inducir artificialmente discontinuidades entre, por ejemplo, las 23:00 y las 00:00 horas.

Luego, se normalizaron los valores de macronutrientes (*calories*, *carbs*, *protein*, *fat*, *fiber*) según la cantidad realmente consumida por cada sujeto, expresada en la variable *amount_consumed*. Esta operación se efectuó a través de una función personalizada que ajusta el contenido nutricional a la proporción efectivamente ingerida (por cada 100 gramos), con el fin de evitar sobreestimaciones al considerar únicamente los valores por porción estándar.

Posteriormente, se crearon variables compuestas de salud intestinal y producción de gases (*gut_health_index* y *gas_production_index*, respectivamente), mediante la suma de indicadores previamente disponibles. Estas nuevas variables resumen en una sola métrica el estado intestinal y los posibles efectos fermentativos de los alimentos, permitiendo así reducir la dimensionalidad y facilitar interpretaciones clínicas más directas. Las variables originales que dieron lugar a estos índices fueron eliminadas.

Además, se incorporaron indicadores de comparación entre sensores para el caso del dataset combinado (*metrics_both_df*). Esto incluyó:

- *delta_ratio*: razón entre el incremento glucémico observado en el sensor Libre frente al del sensor Dexcom.
- *variability_ratio*: razón entre la variabilidad glucémica (desviación estándar) registrada por ambos sensores.
- *mean_variability*: promedio de la variabilidad entre ambos sensores, como indicador robusto del comportamiento postprandial global del paciente.

Finalmente, se construyó una variable denominada *post_meal_state*, calculada como el producto entre la frecuencia cardíaca promedio (*mean_hr*) y los equivalentes metabólicos (*mean_mets*) durante la ventana postprandial. Esta métrica busca captar el nivel de activación fisiológica del sujeto tras la ingesta, integrando parámetros del sistema cardiovascular y del gasto energético. En general, estas transformaciones y agregaciones permiten enriquecer los *datasets* con variables más interpretables, comparables y potencialmente predictivas para su aplicación en modelos de análisis de salud metabólica, digestiva y glucémica.

4.5. Análisis exploratorio

Con los dos conjuntos de datos completos, se realizó un análisis exploratorio de datos para hacer limpieza y preprocesamiento correspondiente en caso de necesitarse. En este procedimiento se destaca la limpieza y procesamiento de las variables que representan el área incremental bajo la curva, pues a pesar del proceso de validación y filtrado que se realizó, algunos registros de alimentos no encontraron una ubicación previa o posterior para tener un valor de iauc positivo, es decir, seguían existiendo registros con un valor de 0 para el área incremental bajo la curva. Esto es fisiológicamente posible, pero se analizaron los casos y se determinó que muchos de ellos eran errores de registro.

Se implementó un procedimiento de imputación de valores que se reconocieron como “faltantes”, siendo realmente valores con iauc = 0 y más de 15g de carbohidratos consumidos. Se utilizaron modelos de regresión basados en gradient boosting, específicamente XGBRegressor. Primero, se definieron las variables predictoras a

emplear en los modelos, que incluían características, antropométricas, clínicas y del microbioma. Para la imputación de la variable *iauc_libre*, se seleccionaron únicamente las observaciones que no requerían imputación, extrayendo de ellas las variables independientes que serían las *features*, y la variable dependiente, es decir, el iAUC. Esta última fue transformada mediante la función logarítmica natural ajustada $\log_1 p$, con el fin de estabilizar la varianza y mejorar la capacidad predictiva del modelo.

Posteriormente, se entrenó el modelo regresor con 500 estimadores y una profundidad máxima de 10, utilizando los datos transformados. Con el modelo entrenado, se predijeron los valores log-transformados de *iauc_libre* para las observaciones que requerían imputación. Dichas predicciones fueron posteriormente revertidas a su escala original utilizando la función $\exp m1$, y los valores resultantes fueron asignados al conjunto de datos original.

Se replicó un procedimiento análogo para la variable *iauc_dexcom* para finalmente, con el objetivo de mitigar el efecto de valores atípicos en las variables imputadas, se aplicó un procedimiento de recorte basado en el rango intercuartílico (IQR) para restringir los valores de *iauc_libre* e *iauc_dexcom* dentro de dicho rango. Este enfoque permitió una imputación coherente de las métricas glucémicas postprandiales, asegurando al mismo tiempo la consistencia estadística de los valores resultantes, sin generar picos de frecuencia sintéticos en ciertos valores.

En la figura 9 se muestra la distribución de frecuencias original en las variables *iauc_libre* e *iauc_dexcom*, las cuales muestran una distribución altamente sesgada a la derecha, mostrando una moda extremadamente alta en 0, y valores positivos muy extremos. En la figura 10 se muestra la distribución de frecuencias generada a partir del preprocesamiento descrito anteriormente, se muestra una distribución igualmente sesgada pero mucho más equilibrada y sin valores extremos.




Figura 9. Distribución de frecuencias de las variables *iauc_libre* e *iauc_dexcom*.




Figura 10. Distribución de frecuencias para las variables *iauc_libre* e *iauc_dexcom* tras preprocesamiento de las variables realizado con *XGBRegressor* y análisis intercuartílico.

Entre otros procesos realizados en el análisis de datos, se exploraron las diferentes correlaciones entre variables y otras distribuciones bivariadas que se discuten y exploran a fondo en la sección de resultados en el apartado de análisis descriptivo de los datos. También se realizó una selección de variables a partir del análisis de correlación, así como según la información que aportan y basándose en investigación previa, definir cuál es su relevancia hacia un modelo de predicción de carbohidratos. También como parte

del preprocesamiento del *dataset* se realizó el *encoding* de variables categóricas para poder finalmente entrenar modelos de predicción.

4.6. Modelado

La predicción de carbohidratos ingeridos en un alimento o comida a través de múltiples variables glucémicas, fisiológicas, clínicas y de microbioma, es un problema de aprendizaje supervisado en el que se entrena un modelo con valores reales obtenidos y se busca que encuentre patrones en los datos con los que se entrena para poder predecir nuevos. Es también un problema de regresión porque el objetivo del modelo es estimar una cantidad numérica: la cantidad de carbohidratos ingeridos en gramos, en este caso. Este tipo de variable es numérica y continua, no categórica ni discreta, es decir, no se busca clasificar dentro de una clase según las entradas al modelo.

Los modelos de regresión son adecuados para este tipo de casos cuando la salida puede tomar cualquier valor real (dentro de los límites fisiológicos o razonables) en función de las características de entrada pues se considera que existe una relación funcional entre las variables independientes (como glucosa postprandial, microbioma, etc.) y la variable dependiente (gramos de carbohidratos). La regresión permite modelar esta relación y predecir nuevos valores.

Primero se realizó una división de datos en conjunto de entrenamiento (*train*) y de prueba (*test*). Esta división se hizo siguiendo la metodología “*leave one group out*” la cual permitió establecer un panorama en el que el modelo se entrena con los datos conjuntos de un grupo de personas, y se prueba con datos de otro grupo de personas que el modelo no ha visto jamás. De esta manera el modelo fue entrenado en un ambiente “real” en el que puede predecir los carbohidratos de una persona nueva en el sistema, solamente teniendo una recolección previa de datos fisiológicos y clínicos.

Posteriormente se eliminaron variables que podrían aportar fuga de datos (*data leakage*) como los demás macronutrientes, el indicador del paciente y el tipo de comida, para proceder con el entrenamiento de modelos de regresión. Se entrenaron tres tipos de

modelos, el *RandomForestRegressor*, *XGBRegressor* y *Stack Model* que combina varios modelos de regresión, en este caso combinando los dos anteriores con *SupportVectorRegressor* y *RidgeRegression*. Cada modelo tiene sus aportaciones distintas:

RandomForestRegressor “construye un conjunto de árboles de decisión entrenados con muestras aleatorias y combina sus resultados, logrando alta precisión y control del sobreajuste de manera efectiva” (sklearn, s.f.). Este enfoque aprovecha la sabiduría de conjuntos: reduce la varianza del modelo (mitigando el sobreajuste) a la vez que mantiene la capacidad de modelar relaciones complejas.

Por su parte el *XGBRegressor* entrena un conjunto de árboles de decisión en secuencia, ajustando cada uno sobre los residuales del anterior, lo que le permite modelar relaciones complejas de forma robusta (xgboost, s.f.). Y un enfoque de modelos *stacking* o apilados, combinan varios estimadores de base entrenados en paralelo y luego sus salidas se usan como entrada de un modelo final (meta-estimador) que aprende a realizar la predicción definitiva (sklearn, s.f.).

Con estos modelos se logra la captura de relaciones no lineales y complejas por la interacción entre múltiples variables, son robustos a la entrada de datos integrando varios features y también siendo robustos al manejo de ruido en los datos. En general capturan la complejidad de la dinámica glucémica de manera que los modelos lineales simples no podrían, mejoran la precisión mediante la agregación de predicciones, y generalizan bien a nuevos pacientes o situaciones gracias a las técnicas de ensemble y regularizaciones empleadas.

4.7. Clustering

Para la creación de perfiles de alimentos se entrenó un modelo de aprendizaje no supervisado, el cual a través de las características de variables glucémicas del sensor Libre y los macronutrientes, pudiera definir distintos perfiles de alimentos en función de

sus macronutrientes y la respuesta glucémica que causan. Para este proceso se utilizó K-Means.

K-Means permite *clusterizar* alimentos según sus métricas glucémicas (p. ej. valores de sensores continuos) y macronutrientes de forma natural: cada clúster queda representado por un centroide (promedio) que resumiría un “perfil” glucémico-nutricional típico del grupo. K-Means es eficiente y escalable incluso con muchos datos (sklearn, s.f.).

Además, se creó otro modelo que definiera grupos de alimentos, pero esta vez solamente basado en la información de glucosa, fisiología, clínica y del microbioma, para poder utilizar esta variable, que contempla toda esta información como otra característica de entrada para un modelo de predicción de carbohidratos.

4.8. Segundo modelo

Para un segundo modelo de predicción de carbohidratos, se añadió al conjunto de *features* una variable que se obtuvo a partir del *clustering* hecho con las características de cada sujeto de estudio, así como de su respuesta glucémica postprandial, pero sin tomar en cuenta variables que pudieran representar *data leakage*. Con este conjunto de datos con la variable agregada, se entrenó un modelo de regresión XGBRegression para comparar los resultados con modelos anteriores, y analizando la influencia de esta variable.

5. RESULTADOS

Durante el análisis exploratorio de datos se exploraron las características del grupo de personas que fueron estudiadas, desde sus perfiles demográficos hasta sus variables fisiológicas y clínicas, además de todas las comidas que fueron ingeridas y registradas. Esto permitió tener un entendimiento claro del conjunto de datos para su preprocesamiento y su uso en entrenamiento de modelos. Se considera que este paso es muy importante porque también permite identificar patrones, relaciones y tendencias que ayuden a tomar decisiones sobre la transformación de los datos. En esta sección se presentan los descubrimientos del conjunto de datos, los resultados de los modelos entrenados para la predicción de carbohidratos y del *clustering* hecho para perfiles de alimentos según la respuesta glucémica.

5.1. Análisis descriptivo de los datos

5.1.1. Conjunto de comidas “*meals*”

Se realizó el análisis exploratorio de los datos específico de cada evento de comida, para esté se encontró que existen 1.706 eventos de comida registrados creados por los 45 pacientes del estudio. Para cada uno de ellos se tiene una medición de los dos sensores de glucosa, el ritmo cardíaco, las calorías de la actividad que realizaban, la energía (en calorías) que gasta la persona al realizar la actividad física actual, el tipo de comida que consumieron, las calorías del alimento, los macronutrientes (*carbs*, *protein*, *fat*), y un micronutriente (como la fibra). También la cantidad consumida, la foto del alimento y qué sujeto tomó el alimento.

Tras el preprocesamiento de datos, para los eventos de comida se encontró que, como se muestra en la tabla 2, en al menos un alimento alguno de los macronutrientes no estaba presente, por eso su mínimo es 0g. Además, el macronutriente que en media se encuentra en mayor proporción son los carbohidratos con 50.14g, seguido de la proteína con 25.5g, después de la grasa con 19.2g y finalmente la fibra, que es normal que se encuentre en menor cantidad, solamente con 17.5g.

	fiber	carbs	protein	fat
count	1706	1706	1706	1706
mean	4.67320633	50.4106155	25.5204572	19.2286635
std	5.18100561	31.4282911	19.8995247	16.0244836
min	0	0	0	0
25%	0	24	10	10
50%	4	49	22	14
75%	7	73	38	30
max	17.5	146.5	69	60

Tabla 2. Resumen descriptivo de la distribución de los datos de macronutrientes para el conjunto de datos de CGMacros tras preprocesamiento.

En la figura 11, 12, 13 y 14 se encuentran la distribución para cada variable de macronutrientes junto al *boxplot* que indica una variable sin *outliers* en todos los casos. Se puede observar que casi en ningún caso se crearon picos de frecuencias sintéticos, manteniendo una distribución con valores “extremos” sin afectar a los demás valores.




Figura 11. Distribución y boxplot de la variable fiber.




Figura 12. Distribución y boxplot de la variable carbs.




Figura 13. Distribución y boxplot de la variable protein.




Figura 14. Distribución y boxplot de la variable fat.

También se encontró que, en los 1.706 eventos de comida hay una distribución relativamente equilibrada entre las tres comidas principales del día: la cena representa la mayor proporción con 492 registros, seguida del desayuno con 436 y la comida con 435,

lo cual sugiere una buena cobertura para comparar entre estos grupos. Por otro lado, los snacks están menos representados con 343 registros, lo que podría deberse a una menor frecuencia real, menor prioridad en el registro por parte de los participantes o una mayor dificultad para identificarlos.

En cuanto a los macronutrientes consumidos en cada tipo de comida, en la tabla 3 se muestran las medias de los macronutrientes consumidos para cada uno. Se puede observar que los almuerzos (*lunch*) son las comidas que tienen en general más carbohidratos, grasas, proteínas (el segundo) y fibra, es decir, suele ser el alimento más fuerte del día para los pacientes de este estudio, al menos en valores medios. El desayuno (*breakfast*) suele ser el segundo más fuerte, siguiendo de la cena (*dinner*) y finalmente las colaciones (*snack*), que tiene sentido porque suelen ser comidas más pequeñas, entre comidas grandes. Debido a estas tendencias la variable *meal_type* podría ser una fuerte predictora, sin embargo, no cumple con el objetivo del proyecto para la automatización de registros porque sería un dato que tendría que registrarse manualmente.

meal_type	carbs	fat	protein	fiber
breakfast	58.74	22.85	35.42	1.32
dinner	47.23	18.73	22.7	5.2
lunch	64.34	25.57	33.74	8.54
snack	26.71	7.3	6.56	3.28

Tabla 3. Media de macronutrientes consumidos para cada tipo de comida.

En cuanto a la correlación que existe entre macronutrientes y contenido general de los alimentos del conjunto de datos, en la figura 15 se encuentra un mapa de calor que muestra estas correlaciones. Las variables *carbs*, *protein* y *fat* tienen una correlación positiva moderada entre sí, lo que es esperado ya que son macronutrientes que suelen estar presentes en las comidas. La variable *fiber* tiene una correlación positiva más débil con *carbs*, *protein* y *fat*, lo que sugiere que las comidas con más fibra no necesariamente tienen más de los otros macronutrientes. La variable *calories* está más correlacionada

con la variable *fat* y con *carbs*, lo que indica que a mayor cantidad de carbohidratos y de grasas, más calorías se ven en los alimentos, lo que tiene mucho sentido nutricional.




Figura 15. Mapa de calor de las correlaciones entre variables de contenido nutricional y energético de las comidas del conjunto de datos *CGMacros*.

5.1.2. Conjunto de datos “*bio*”

Este conjunto de datos contiene variables demográficas y clínicas sobre los 45 sujetos de estudio, los cuales tienen una media de edad de 48 años, el menor tiene 18 años y el mayor 69 años. En cuanto a su peso, la media es de 182 lb, un mínimo de 116 lb y máximo de 284 lb. La altura media es de 64.3 in, la altura más pequeña es de 59 in y la más alta es de 72 in.

En cuanto a medidas de laboratorio, se tiene lo siguiente:

- **a1c_pdl_(lab):** La mayoría de los valores se sitúan en el rango normal-alto o prediabético (5.7–6.4 %), aunque algunos se acercan a niveles diagnósticos de diabetes (>6.5 %). El valor máximo (8.5 %) sigue estando dentro de un rango clínicamente posible, por lo que no hay indicios de errores en los datos.

- **fasting_glu_pdl:** Una proporción considerable de individuos podría estar en estado de prediabetes o diabetes, ya que más del 50% tienen niveles > 100 mg/dL. El valor máximo de 218 mg/dL es un *outlier* clínicamente plausible.
- **insulin:** La mayoría de los valores están dentro del rango normal ($2\text{--}25$ $\mu\text{U/mL}$). El valor de 46.4 $\mu\text{U/mL}$ se identifica como un outlier, lo que podría indicar un caso de hiperinsulinemia o una medición fuera de ayuno.
- **tryglicerides:** La mayoría de los valores se encuentran en un rango normal o ligeramente elevado, pero algunos valores superan la barrera de 200 mg/dL que es un valor alto.
- **cholesterol:** Valores concentrados alrededor del rango saludable, pero con algunos casos extremos. La mayoría de los individuos están en el rango normal o límite alto (entre 150–240 mg/dL). El valor máximo de 345 mg/dL indica colesterol muy elevado, posiblemente reflejando riesgo cardiovascular alto o un caso clínico.
- **non_hdl:** los valores se encuentran entre 100 y 160 mg/dL, lo que indica un perfil intermedio a ligeramente elevado, común en poblaciones con riesgo metabólico moderado. Los *outliers* reflejan casos con colesterol no-HDL muy alto (≥ 240 mg/dL), lo cual incrementa el riesgo cardiovascular.

5.1.3. Conjunto de datos “gut_scores_imputed”

En la figura 16 se muestra la distribución de frecuencias del conjunto de datos. Al ser un DataFrame conformado únicamente por valores ordinales entre 1 y 3, su información se encontró bastante ordenada desde el inicio, con pocas modificaciones que realizar.

El dataset revela que la mayoría de las puntuaciones se concentran en el nivel intermedio (2), indicando que la salud intestinal de los sujetos tiende a ser promedio. Sin embargo, en varias variables relevantes como *Butyrate_Production*, *Metabolic_Fitness* y *Digestive Efficiency*, las puntuaciones “Good” son escasas, lo cual sugiere que pocos participantes presentan un perfil microbiótico altamente favorable. A la vez, hay otras variables como *Biofilm_Chemotaxis* y *Virulence_Pathways*, *TMA_Production*, *Gas_Production* y

Sulfide_Gas_Production donde predominan puntuaciones bajas (1), lo que podría reflejar una actividad microbiana potencialmente perjudicial en varios sujetos.

Estas observaciones permiten identificar posibles rutas microbianas candidatas para correlacionar con métricas de respuesta glucémica como el área incremental bajo la curva (iAUC) o el cambio máximo postprandial. Variables como *Metabolic_Fitness*, *Gut_Microbiome_Health*, *Inflammatory_Activity* o *Butyrate_Production* son especialmente relevantes debido a su vínculo conocido con el metabolismo de la glucosa, la resistencia a la insulina y la inflamación sistémica.



Figura 16. Distribución de frecuencias de las variables categóricas para *gut_scores_imputed* del conjunto de datos *CGMacros*.

5.1.4. Respuesta glucémica postprandial

Después de hacer la validación de eventos de comida y sus registros postprandiales, se obtuvieron curvas de glucosa postprandiales como las que se mostraron anteriormente, y como la que se muestra en la figura 17, en donde se observan para dos sensores con marcadores el inicio del evento de comida y el pico máximo de la curva de glucosa. Además, a un costado se observa una fotografía del alimento en cuestión que se tiene registrado en el conjunto de datos con su respectiva ruta de origen de la imagen, en este caso, una comida de la marca “Chipotle”.




Figura 17. Curva de glucosa para el sensor Dexcom y el sensor Libre de la respuesta glucémica postprandial junto a la imagen del alimento consumido.

Posteriormente a que fueron calculadas las métricas de glucosa necesarias derivadas del área incremental bajo la curva y tras su preprocesamiento, se analizaron las distintas correlaciones de las curvas de glucosa para cada macronutriente. En la figura 18 se observa la correlación entre los macronutrientes y el sensor glucémico Libre, y en la figura 19 para el sensor glucémico Dexcom.




Figura 18. Correlación entre macronutrientes y las métricas de respuesta glucémica postprandial del sensor Libre.




Figura 19. Correlación entre macronutrientes y las métricas de respuesta glucémica postprandial del sensor Dexcom.

En ambos casos, se observa que los carbohidratos son el nutriente más consistentemente asociado con el aumento glucémico, especialmente con *iauc*, *delta* y *variability*, con coeficientes de correlación entre 0.11 y 0.27. Esto sugiere que, a mayor cantidad de carbohidratos en una comida, mayor es la respuesta glucémica medida por ambas tecnologías, por ejemplo, mayor iAUC, mayor el delta o diferencia entre valor basal y pico máximo, mayor es el pico de glucosa como tal, y la desviación estándar de la curva.

Por el contrario, la fibra muestra una correlación negativa con todas las métricas, alcanzando hasta -0.23, lo que indica que su presencia podría estar asociada con una menor respuesta glucémica, posiblemente por su efecto modulador en la absorción de glucosa, es decir, a mayor cantidad de fibra, menor iAUC y sobre todo menor valor de pico máximo y diferencia entre valor basal y máximo. En cambio, las correlaciones de proteína y grasa con las métricas glucémicas son muy bajas o cercanas a cero, lo que indica un efecto mucho menos relevante o indirecto en la respuesta postprandial medida por los sensores.

También se analizó la correlación entre los macronutrientes con otras métricas demográficas y de salud de los individuos, esta se muestra en la figura 20, en la cual se observa que las correlaciones son bajas o cercanas a cero, las más altas son el ritmo cardíaco medio en la ventana de dos horas posteriores a la ingesta de alimentos y los carbohidratos consumidos (0.10).




Figura 20. Correlación entre macronutrientes y valores fisiológicos y clínicos de los sujetos de estudio para el conjunto de datos *CGMacros*.

Se realizó también, como se muestra en la figura 21, un análisis de correlación por medio de un *scatterplot* que buscaba entender la relación entre el área incremental bajo la curva y el valor de carbohidratos, proteínas, grasas o fibras consumidas. Se observa que las

correlaciones no son muy precisas en los diagramas lo que revela una dificultad para encontrar los patrones para los modelos por medio de solamente esta métrica.




Figura 21. Scatterplots de la correlación entre los macronutrientes y el iAUC de la respuesta glucémica postprandial.

Visualmente, se observa una tendencia ligeramente ascendente entre los carbohidratos y el iAUC, lo que respalda la correlación positiva detectada anteriormente: a mayor ingesta de carbohidratos, mayor suele ser la respuesta glucémica. Esto se visualiza en la acumulación de puntos en valores inferiores y sobre todo en que para valores más altos de carbohidratos esta acumulación severa de valores bajos de iAUC deja de existir.

En contraste, para proteína, grasa y fibra, no se aprecia una relación clara ni consistente con el iAUC. Aunque hay una ligera acumulación de puntos en rangos bajos y medios, los valores de iAUC se mantienen dispersos a lo largo de todo el espectro. Esto refuerza la conclusión de que los carbohidratos son el principal determinante nutricional de la respuesta glucémica, mientras que los otros macronutrientes tienen un efecto más atenuado o indirecto.

También se analizó la respuesta glucémica del iAUC media para cada paciente. En la figura 22 se muestra este gráfico que muestra valores interesantes en los que para algunos pacientes se observaron en general observaciones de iAUC mucho más grandes que para otros.




Figura 22. iAUC medio para cada paciente del estudio de CGMacros.

El gráfico permite visualizar diferencias notables entre ambos sensores en algunos casos, aunque en otros se mantiene bastante coherente. Son interesantes los casos los participantes con mayor respuesta glucémica promedio como son el número 49 y el número 33. Los que menos respuesta glucémica tuvieron son el 6 y 15. Al analizar a estos pacientes, se encontró que el paciente 49 consumió en promedio 57 g de carbohidratos por comida, mientras el 6 consumió 53 g de carbohidratos de media.

También se analizó la respuesta glucémica postprandial para cada tipo de comida registrado, se muestra en la figura 23, y se visualiza que existen diferencias claras en la respuesta glucémica según el momento del día. Tanto para el sensor Libre como para Dexcom, el desayuno (*breakfast*) presenta los valores medianos y máximos de iAUC más elevados, lo que sugiere que las comidas matutinas generan mayores incrementos de glucosa postprandial. En contraste, los snacks tienden a mostrar valores más bajos y concentrados, reflejando respuestas glucémicas más moderadas. Las comidas principales como *lunch* y *dinner* presentan una distribución más dispersa, indicando mayor variabilidad entre individuos. Estos patrones podrían estar relacionados con factores hormonales, contenido nutricional o el tiempo en ayuno previo a cada comida.




Figura 23. Distribución de iAUC para cada tipo de evento de comida medido por los sensores Libre y Dexcom.

El análisis de correlación entre las variables de respuesta glucémica y variables clínicas que se muestra en la figura 24 reveló una correlación clínica destacada, específicamente entre la hemoglobina glucosilada (HbA1c) y las métricas de glucosa postprandial, especialmente con el valor pico tanto en el sensor Libre ($r = 0.62$) como en Dexcom ($r = 0.57$), lo que sugiere que individuos con mayor HbA1c tienden a alcanzar niveles más altos de glucosa tras las comidas.

Otras variables clínicas como colesterol, BMI, y non-HDL muestran correlaciones muy bajas o negativas, lo cual indica que su relación con las respuestas glucémicas agudas

es débil o inexistente en este conjunto de datos. La salud del revestimiento intestinal (*gut_lining_health*) tiene correlaciones ligeramente positivas, pero poco significativas, lo que puede apuntar a un papel secundario o más complejo en la modulación glucémica.




Figura 24. Correlación entre variables clínicas y métricas de respuesta glucémica postprandial.

5.2. Resultados del modelado

Se entrenaron y estudiaron tres tipos de modelos de regresión, y en uno de ellos se hicieron algunas pruebas complementarias cambiando la variable objetivo (carbs) para verificar si existía una mejora en las predicciones. Además para cada modelo se aplicó un proceso de optimización de hiperparámetros para encontrar el modelo óptimo para resolver el problema, y tras un proceso de explicabilidad en el que se reconocieron las variables que más toma en cuenta cada modelo para realizar sus predicciones, los modelos fueron reentrenados para evitar el ruido generado por otras variables. Otro modelo entrenado fue el de clustering para la creación de perfiles de alimentos.

5.2.1. RandomForestRegressor

Este modelo obtuvo que los mejores parámetros fueron: `n_estimators = 330`, `max_depth = 20`, `max_features = 0.3`, `min_samples_split = 5`, `min_samples_leaf = 8` y `bootstrap = True`.

El desempeño del modelo se evaluó sobre un conjunto de prueba independiente, obteniendo un RMSE (*Root Mean Squared Error*) de 23.54 g de carbohidratos, y un coeficiente de determinación $R^2 = 0.271$ que indica que el modelo fue capaz de explicar aproximadamente el 27.1% de la varianza observada en la variable objetivo. Aunque la capacidad explicativa es limitada, el desempeño resulta relevante considerando la alta heterogeneidad individual en la respuesta glucémica postprandial y la ausencia de información directa sobre los alimentos ingeridos (modelo inverso basado en respuestas fisiológicas).

En la figura 25 se muestra la dispersión “Real vs. Predicho”, en esta se observa una tendencia general creciente entre los valores reales y las predicciones, aunque con cierta dispersión y un sesgo hacia la subestimación de valores altos.




Figura 25. Gráfica de dispersión de comparación de los valores reales contra los predichos por el modelo de regresión RandomForestRegressor.

Respecto a la interpretación del modelo, se analizó la importancia de variables a través de dos enfoques complementarios: la importancia basada en el criterio Gini y los valores de SHAP (SHapley Additive exPlanations). En la gráfica de importancia de características que muestra en la figura 26, destacan como más relevantes las variables relacionadas con el momento de consumo de los alimentos (*meal_time_hour_sin* y

meal_time_hour_cos), seguidas por indicadores de respuesta glucémica como el *iAUC_libre*, *delta_libre* y *iAUC_dexcom*. También se posicionan como relevantes medidas de variabilidad glucémica y tiempos de respuesta postprandial (*time_to_peak_dexcom*, *variability_libre*, etc.), lo cual refleja una fuerte influencia del perfil glucémico dinámico en el valor a predecir.




Figura 26. Importancia de las características para la predicción del modelo de regresión RandomForestRegressor.

La gráfica de valores SHAP de la figura 27 se confirma esta importancia, indicando no solo la relevancia global de las variables, sino también su impacto individual en cada predicción. Por ejemplo, valores elevados de *meal_time_hour_sin*, *iAUC_libre* y *delta_libre* se asocian con un aumento en las predicciones del modelo, mientras que bajos valores en ciertas métricas, como *variability_dexcom*, tienden a reducir la salida del modelo.




Figura 27. Relevancia global de las variables por medio de SHAP para el modelo de regresión RandomForestRegressor.

Este análisis de interpretabilidad permite validar la coherencia del modelo con el dominio clínico y metabólico del problema, y sugiere que el momento del día, junto con la dinámica de la respuesta glucémica individual, son factores determinantes en la predicción de la variable objetivo. Asimismo, variables clínicas tradicionales como HbA1c (*a1c_pdl_lab*) y edad aparecen con importancia media, mientras que aspectos microbianos y metabólicos contribuyen en menor medida.

Después se bajó el número de *features* según las 5 variables más importantes en los análisis de importancia, y se entrenó el RandomForestRegressor con los mismos parámetros, pero solamente los datos de entrenamiento seleccionados, obteniendo un RMSE de 23.23g de carbohidratos y un $R^2 = 0.29$, lo cual representó una leve mejora frente al modelo anterior.

5.2.2. XGBRegressor

Para este modelo se obtuvo como configuración óptima: $n_estimators = 456$, $max_depth = 6$, $learning_rate = 0.0108$, $gamma = 1.89$, $subsample = 0.54$ y $colsample_bytree = 0.58$. Esta configuración permitió controlar el riesgo de sobreajuste y mejorar la capacidad generalizadora del modelo.

El desempeño sobre el conjunto de prueba fue ligeramente superior al modelo de Random Forest, con un RMSE de 23.25 gramos de carbohidratos y un coeficiente de determinación $R^2=0.289$. Esto indica que el modelo XGBoost logró explicar aproximadamente el 28.9% de la variabilidad en la cantidad real de carbohidratos ingeridos a partir de los datos de sensores, variables fisiológicas, clínicas y del microbioma.

Como se observa en la figura 28, la dispersión de valores predichos frente a valores reales muestra un patrón similar al observado con Random Forest: una subestimación sistemática de eventos con ingestas elevadas y una concentración de predicciones en torno a un rango medio. Esto puede estar asociado a la distribución sesgada de los datos o a la limitada señal predictiva presente en los rangos extremos.




Figura 28. Gráfica de dispersión de comparación de los valores reales contra los predichos por el modelo de regresión XGBRegressor.

Desde la perspectiva de la interpretabilidad, se emplearon valores SHAP para analizar el impacto individual de cada variable sobre la salida del modelo. Los resultados, mostrados en la figura 29, muestran una alta concordancia con los modelos previos, destacándose como variables más influyentes el horario de la comida, reflejando la importancia del momento del día en la respuesta glucémica y, por ende, en la inferencia del tipo y cantidad de alimentos ingeridos. Las medidas de respuesta glucémica que actúan como proxies de la carga glucémica del alimento, parámetros clínicos y factores de estilo de vida que inciden en el metabolismo postprandial.




Figura 29. Relevancia global de las variables por medio de SHAP para el modelo de regresión XGBRegressor.

Tras aplicar el mismo procedimiento que con RandomForestRegressor, se obtuvo un modelo que aumentó el RMSE y disminuyó la variabilidad captada por el modelo inicial, por lo mismo se mantendría en este caso un entrenamiento con todas las *features* originales.

5.2.2.1. Con transformación logarítmica de la variable carbs

Con el objetivo de mejorar la distribución de la variable dependiente (carbohidratos ingeridos) y mitigar el impacto de valores atípicos o altamente sesgados, se exploró una transformación logarítmica natural previa al entrenamiento del modelo, seguida de una destransformación exponencial de las predicciones al finalizar el proceso. Esta técnica es común en problemas donde la variable a predecir presenta una distribución altamente asimétrica, ya que puede favorecer una mejor estabilidad numérica y ajuste del modelo.

Para esta configuración, se empleó nuevamente el algoritmo XGBoost, ajustando los hiperparámetros mediante búsqueda bayesiana. Los valores óptimos obtenidos fueron: $n_estimators = 697$, $max_depth = 10$, $learning_rate = 0.0678$, $gamma = 3.66$, $subsample = 0.71$, $colsample_bytree = 0.56$.

No obstante, el modelo resultante presentó un rendimiento inferior al de los modelos previos sin transformación logarítmica. En el conjunto de prueba, se obtuvo un RMSE de 28.23 gramos de carbohidratos y un coeficiente de determinación $R^2 = -0.048$ en el que este valor negativo sugiere que el modelo tuvo un desempeño peor que una predicción constante basada en la media del conjunto de entrenamiento.

Este resultado pone en evidencia que, en el contexto específico de este problema, la transformación logarítmica no fue beneficiosa. Es posible que el proceso de transformación inversa haya amplificado errores en la escala original, particularmente para eventos con bajas ingestas de carbohidratos, donde pequeñas diferencias en la escala logarítmica pueden traducirse en errores absolutos mayores tras aplicar la función exponencial. Además, subrayan la importancia de considerar no solo la distribución de la variable objetivo, sino también el impacto que una transformación y su inversa pueden

tener en las métricas de evaluación en la escala original, especialmente cuando se requiere una interpretación clínica o nutricional directa de las predicciones.

5.2.3. Modelo de Stacking

Este modelo está compuesto por tres estimadores bases RandomForestRegressor, XGBRegressor y SVR con escalado previo, y un estimador final RidgeRegression encargado de combinar las predicciones de los modelos base. A través de una búsqueda exhaustiva de hiperparámetros mediante validación cruzada. Se identificaron los parámetros óptimos para cada componente del ensamblado, destacando un número de 600 árboles para el Random Forest, una tasa de aprendizaje de 0.03 para XGBoost, un valor de C igual a 0.1 para el SVR y un valor de alpha de 0.5 para la regresión Ridge.

El rendimiento del modelo se evaluó con un RMSE de 23.31 y un coeficiente de determinación $R^2 = 0.285$. El gráfico de dispersión de la figura 30 muestra las predicciones hechas contra los valores reales, y se revela una tendencia a la subestimación de valores altos de carbohidratos, con predicciones que tienden a concentrarse en valores medios, lo que sugiere un posible sesgo derivado de la distribución del conjunto de entrenamiento.




Figura 30. Valores reales vs predichos del modelo de predicción por Staacking.

5.2.4. Clustering

Con el fin de identificar perfiles diferenciados de respuesta glucémica y características nutricionales asociadas a los eventos alimentarios se realizó análisis no supervisado por *clustering*. Se aplicó el algoritmo de K-Means y se determinó el número óptimo de clústeres evaluando tanto la inercia (método del codo) como la métrica Silhouette Score. Ambos criterios convergieron en que el valor óptimo de $k=3$, lo que sugiere la presencia de tres agrupaciones representativas dentro de los datos, esto se puede observar en las figuras 31 y 32.




Figura 31. Elbow method




Figura 31. Silhouette score

Una vez determinado el número óptimo de clústeres, se ajustó el modelo y se asignó cada muestra a su grupo correspondiente. El análisis de los perfiles promedio de cada clúster reveló diferencias sustanciales entre grupos, estos se pueden observar en la tabla 4, en donde se observa que el Cluster 0 se caracteriza por una ingesta moderada de carbohidratos (~25 g) y respuesta glucémica intermedia, podría decirse que es el perfil de una comida baja en carbohidratos y con una respuesta glucémica consecuentemente bajo, un “*snack*”; el Cluster 1 muestra una ingesta elevada (~64 g) con una respuesta glucémica notablemente más alta, también se observa una cantidad baja de otros macronutrientes como proteínas y fibras, podría decirse que es una comida “no balanceada”. El Cluster 2 presenta los valores más altos tanto en ingesta como en contenido calórico, pero una respuesta glucémica intermedia en comparación, probablemente debido al alto contenido en otros macronutrientes como proteínas y fibra.

Esta segmentación permite identificar posibles patrones fisiológicos y nutricionales que podrían ser útiles para personalizar recomendaciones dietéticas o ajustar modelos predictivos.

Cluster	calories	carbs	protein	fat	fiber	iauc_libre
0	310.8430034	29.79959044	19.66979522	10.6512372	4.058481229	1483.475587
1	500.9738189	59.53937008	27.08897638	16.62923228	2.473622047	5900.994289
2	796.398	76.14946667	39.10922222	32.95433333	6.473333333	2420.963149

Tabla 4. Clusters de perfiles de tipos de alimentos según sus macronutrientes y su respuesta glucémica postprandial.

Finalmente, se aplicó un análisis de componentes principales (PCA) para reducir la dimensionalidad y visualizar los clústeres en el espacio bidimensional. La proyección de la figura 32 muestra una separación clara entre los tres grupos, lo cual valida visualmente la estructura identificada por el algoritmo de *clustering*. Esta clasificación no supervisada aporta una nueva perspectiva sobre la heterogeneidad interindividual en la respuesta a los alimentos y puede ser utilizada para refinar futuros modelos o guiar estrategias de intervención personalizadas.




Figura 32. Clusters en el espacio bidimensional tras PCA.

5.2.4.1. XGBRegressor con variable de cluster

Debido a la correlación mostrada por el tipo de comida en el análisis exploratorio de datos, se probó crear clusters de acuerdo con la información fisiológica y glucémica para utilizar estos clusters como variable de entrenamiento. Se siguió el mismo procedimiento que anteriormente para un XGBRegressor con la reducción de sus características.

Entre los parámetros más relevantes se encuentran una profundidad máxima de 8, un conjunto de 317 árboles, y una tasa de aprendizaje baja, lo cual sugiere un enfoque conservador enfocado en minimizar el sobreajuste a través de un entrenamiento progresivo. En cuanto a su rendimiento, el modelo alcanzó un RMSE de 23.22 y un R^2 de 0.291 sobre el conjunto de prueba. En la figura 33 se muestra la relación entre los valores de prueba reales contra los predichos.




Figura 33. Valores de prueba reales contra predichos para el modelo XGBRegressor entrenado con la *feature* agregada de los clusters.

Estos resultados son ligeramente superiores a los obtenidos con el modelo ensamblado tipo stacking, el anterior XGBRegressor y el RandomForestRegressor, lo cual sugiere que XGBoost ofrece el mejor desempeño competitivo en la predicción de la ingesta de carbohidratos. Aunque el coeficiente de determinación sigue siendo moderado, el comportamiento del modelo evidencia una capacidad razonable para capturar patrones

complejos en los datos, lo que lo posiciona como una opción sólida dentro del marco comparativo de este estudio.

5.3. Discusión de resultados

El mejor modelo de predicción y por tanto el modelo seleccionado fue el de XGBoost entrenado con todas las características originales. Se considera que confirma la viabilidad del enfoque inverso propuesto en este trabajo: predecir la cantidad de carbohidratos ingeridos a partir de la respuesta glucémica registrada por sensores, sin necesidad de contar con información directa del alimento.

A pesar de que el desempeño aún se encuentra limitado por factores como el ruido en las señales fisiológicas y la alta variabilidad interindividual, los resultados obtenidos consolidan un punto de partida robusto hacia la construcción de herramientas de predicción personalizadas para el ámbito de la nutrición digital y la salud metabólica.

Se debe considerar que en este *dataset* se contaba con diversas limitaciones que impidieron un entrenamiento óptimo del modelo para el entendimiento de patrones, pues la variabilidad de únicamente 45 personas y 1290 registros de comida válidos pueden llegar a ser insuficientes, pero es el único conjunto de datos público existente de estas características. Pues también es importante considerar los beneficios de este enfoque, ya que conjuntos de datos contenían información sobre variables fisiológicas, clínicas y del microbioma intestinal, solo se habían utilizado para predecir, a partir de esta información y los macronutrientes como información conocida, la respuesta glucémica postprandial.

En el caso de otros modelos que predijeran cantidad de carbohidratos consumida, que de por sí no contaban con información como la que se señaló anteriormente y por tanto estaban limitados a personas con características metabólicas y fisiológicas similares, se tenían errores de entre 18g de carbohidratos que, si bien es un error menor al mostrado aquí en aproximadamente 5g, fueron obtenidos en contextos más controlados y con menor heterogeneidad interindividual. En contraste, el presente modelo busca

generalizar la predicción a una población más diversa, incorporando múltiples fuentes de variabilidad como diferencias en microbiota, respuesta glucémica, nivel de actividad física y estado metabólico basal, lo que representa un desafío adicional que justifica parcialmente el aumento en el error absoluto. Asimismo, el enfoque aquí propuesto se centra en maximizar la aplicabilidad práctica y la personalización futura, más que en optimizar exclusivamente métricas tradicionales de regresión.

El coeficiente de determinación obtenido para el modelo seleccionado, $R^2=0.29$ se encuentra dentro del rango considerado como aceptable en la literatura especializada, particularmente en el contexto de modelos inversos que buscan estimar la cantidad de carbohidratos ingeridos a partir de la respuesta glucémica postprandial, como se discutió en el apartado de estado del arte.

Estudios previos han reportado desempeños similares, con valores típicos de entre 0.2 y 0.4, lo que refleja la complejidad inherente del problema. Por ejemplo, Daniels et al. (2023) informaron una considerable dispersión entre el tamaño real de las comidas y las estimaciones generadas por su modelo, mientras que Mosquera-Lopez et al. (2023) concluyeron que su sistema no era capaz de distinguir de forma precisa entre comidas de distintos tamaños. Estas limitaciones se deben a la alta variabilidad interindividual en la respuesta metabólica, al ruido en los datos de sensores, y a la influencia de factores no observables como la composición exacta del alimento, la absorción intestinal, o el contexto fisiológico del momento.

A pesar de ello, ambos trabajos coinciden en que una estimación aproximada de los carbohidratos resulta clínicamente útil. Daniels et al. (2023) demostraron que este tipo de predicciones mejora el tiempo en rango glucémico al integrarse a sistemas de páncreas artificial, mientras que Mosquera-Lopez et al. (2023) evidenciaron que un sistema de control automático sin necesidad de anuncio de comidas puede mitigar la hiperglucemia postprandial casi tanto como si el paciente informara manualmente la cantidad de carbohidratos. En este sentido, el valor de $R^2=0.29$ alcanzado en el presente trabajo debe interpretarse no solo en términos estadísticos, sino también como una contribución

Modelado de la composición de carbohidratos ingeridos utilizando respuesta glucémica postprandial, datos fisiológicos, clínicos y del microbioma mediante aprendizaje automático

Alejandro Magdiel Muñoz Corona

relevante en escenarios donde la automatización, la escalabilidad y la personalización son prioritarias.

6. APLICACIONES Y LÍNEAS FUTURAS

6.1. Propuesta de despliegue en Cloud

6.1.1. Justificación del despliegue

El despliegue en la nube ofrece ventajas clave para el sistema sanitario y la analítica de datos clínicos. Plataformas como AWS permiten integrar datos heterogéneos (sensores, apps móviles, bases de datos) de forma centralizada y segura, habilitando potentes capacidades de cómputo y escalabilidad bajo demanda. En el sector salud se observa una tendencia creciente hacia la nube, donde casi el 70% de organizaciones sanitarias amplían su uso de cloud según Intersystems (InterSystems, s.f.), buscando mejorar la eficiencia operativa y emplear IA/ML en tiempo real.

Además, el modelo de pago por uso y la automatización de recursos que ofrece AWS reducen la necesidad de costosas infraestructuras propias, permitiendo mantener los sistemas actualizados y adaptarse rápidamente a aumentos de carga (por ejemplo, más usuarios o más sensores). La nube es ideal para el modelo de predicción de carbohidratos propuesto porque facilita procesamiento y almacenamiento escalables de datos sensibles en *streaming*, soporte nativo para aprendizaje automático y cumplimiento de normativas.

6.1.2. Arquitectura general propuesta

Se contempla una propuesta con un flujo *end-to-end* de los datos de los usuarios hacia la predicción de carbohidratos consumidos con las siguientes herramientas:

- AWS IoT Core: servicio gestionado para conectar y gestionar dispositivos IoT de forma segura. Los *wearables* o apps móviles pueden publicar datos a AWS IoT Core usando protocolos como MQTT sobre TLS. IoT Core escala con facilidad para múltiples dispositivos y los integra con otros servicios de AWS (AWS, s.f.).
- Amazon API Gateway: Sería la puerta de enlace HTTP RESTful gestionada que recibe solicitudes de clientes o aplicaciones móviles. API Gateway actúa como

capa frontal, manejando autenticación básica, control de acceso y escalado automático de las llamadas al *backend* sin servidores (AWS, s.f.).

- AWS Lambda: Es el servicio de cómputo *serverless* que ejecuta código en respuesta a eventos. Lambda procesa los datos entrantes (p.ej. validación o transformaciones ligeras) y orquesta la llamada al modelo de inferencia. Al ser *event-driven*, permite responder en tiempo real sin mantener servidores activos, pagando solo por la ejecución (AWS, 2025).
- Amazon SageMaker (*Endpoint* de inferencia): Servicio totalmente gestionado para modelos de machine learning. Se despliega el modelo de predicción de carbohidratos como un *endpoint* en SageMaker, ideal para inferencias en tiempo real con baja latencia. Este *endpoint* recibe los datos procesados por Lambda y retorna la predicción inmediatamente (AWS, 2025).
- Amazon S3: Almacenamiento de objetos duradero para datos históricos o archivos de modelo. S3 ofrece alta durabilidad y cifrado de datos por defecto. Se puede usar para almacenar registros brutos o resultados agregados a bajo costo (AWS, 2025).
- Amazon DynamoDB: Base de datos NoSQL gestionada, *serverless*, con latencia de milisegundos y escalado automático. Útil para guardar perfiles de usuarios o resultados de predicción recientes, permitiendo consultas rápidas con elevado rendimiento (AWS, 2025).
- AWS IAM: Gestiona identidades y permisos en la cuenta. Se definen roles de IAM con privilegios mínimos para cada servicio (p.ej. Lambda, IoT Core, SageMaker). Esto asegura que cada componente solo accede a los recursos estrictamente necesarios. IAM también maneja credenciales seguras para los clientes móviles y dispositivos (AWS, s.f.).
- Amazon CloudWatch: Servicio de monitorización que recopila métricas y registros (logs) de los recursos y aplicaciones. Cada función Lambda, el API Gateway y el IoT Core pueden enviar métricas y logs a CloudWatch. Se configuran alarmas básicas (p.ej. errores, tiempo de respuesta) y paneles de control para obtener una visión unificada del estado del sistema (AWS, 2025).

6.1.3. Flujo de datos

El flujo principal sería como sigue: el dispositivo *wearable* mide datos (glucosa) y los envía a la nube (a AWS IoT Core), esto puede hacerse por medio de una primera recepción en la app. Posteriormente la solicitud alcanza el API Gateway, que actúa como interfaz REST. El API Gateway reenvía la petición a una función Lambda. Lambda prepara la información y llama al *endpoint* de SageMaker con los datos del sensor. SageMaker retorna la predicción de carbohidratos a Lambda, que a su vez responde al cliente (a través de API Gateway). De este modo, la predicción está disponible casi en tiempo real para la aplicación o el usuario final.

Además, se propone almacenamiento para los datos entrantes o las predicciones, que pueden almacenarse en Amazon S3 (para análisis histórico o auditoría) o en DynamoDB (para acceso rápido a resultados recientes). S3 garantiza durabilidad y cifrado por defecto, mientras que DynamoDB ofrece un rápido almacenamiento de clave-valor. En la figura 34 se observa el flujo de datos como en la arquitectura planteada anteriormente.




Figura 34. Arquitectura y flujo de datos del despliegue *cloud* de la aplicación para predicción de carbohidratos en la suite de AWS.

6.1.4. Seguridad y privacidad

- Control de acceso (IAM): se usan roles de IAM para cada servicio con permisos mínimos, evitando exponer credenciales raíz. Por ejemplo, la función Lambda tendrá un rol que solo permite llamar al *endpoint* de SageMaker. Las políticas de IAM definen qué acciones puede realizar cada entidad.
- Cifrado en tránsito: todos los datos entre los dispositivos y la nube viajan cifrados mediante TLS (por ejemplo, AWS IoT Core exige TLS por defecto para MQTT/HTTPS). De igual forma, API Gateway y demás comunicaciones internas usan HTTPS/TLS.
- Cifrado en reposo: los datos almacenados en S3 o DynamoDB deben cifrarse con claves gestionadas por AWS KMS. Amazon S3 cifra los objetos por defecto, y DynamoDB cifra automáticamente las tablas; así se protege la confidencialidad en reposo.
- Otras consideraciones: se propone el uso de API Keys o autenticación (p.ej. Amazon Cognito) en API Gateway para autorizar a clientes móviles, y certificados únicos por dispositivo en IoT Core para evitar conexiones no autorizadas.

6.1.5. Monitorización del sistema

Amazon CloudWatch ofrece monitoreo ligero y reactivo. Se recopilan métricas (por ejemplo, latencia de API Gateway, invocaciones/errores de Lambda) y logs (registro de eventos de Lambda, tráfico IoT, etc.). Se configuran alarmas simples (por ejemplo, notificar si aumenta la tasa de errores o cae la invocación del *endpoint*). Con esta visibilidad se asegura que el sistema funciona correctamente y permite diagnosticar problemas de forma ágil.

Esta arquitectura utiliza componentes fundamentales de AWS (IoT Core, API Gateway, Lambda, SageMaker, S3/DynamoDB, CloudWatch, IAM) para cubrir el procesamiento en tiempo real de datos de dispositivos *wearable* de glucosa. Cada servicio cumple una

función clara, desde la conectividad segura, ejecución *serverless*, inferencia en línea hasta almacenamiento básico. La propuesta de arquitectura resulta poco compleja en comparación con soluciones empresariales con muchos servicios de *streaming*, facilitando la implementación práctica.

6.2. Posibles mejoras del modelo

Para mejorar el rendimiento del modelo, se pueden explorar diversas técnicas avanzadas de *feature engineering* y aprendizaje automático. En primer lugar, incorporar imágenes de alimentos mediante visión por computadora puede refinar la estimación de nutrientes. Sistemas como *GoCARB* han demostrado que con fotos de la comida se puede estimar carbohidratos con un error promedio de solo entre 6 g (10% de error), y modelos especializados han logrado errores inferiores a 10 g comparables a dietistas profesionales. Estos métodos, basados en detectar porciones y reconocer alimentos, podrían usarse para generar automáticamente *features* nutricionales precisos (carbohidratos, grasas, proteínas) a alimentar al modelo (Anthimopoulos *et al.* 2015).

También se puede aprovechar la temporalidad de los datos: integrar información previa (niveles de glucosa, calorías gastadas, heart rate) con modelos secuenciales. Redes neuronales recurrentes (LSTM/GRU) o modelos de atención para series de tiempo podrían capturar patrones dinámicos en la respuesta postprandial (por ejemplo, cómo la glucemia cambia 30 min antes y después de comer). Adicionalmente, incluir variables de contexto temporal (hora del día, ritmo circadiano, día de la semana) puede mejorar la detección de patrones alimenticios rutinarios.

La segmentación de cada comida como evento facilita generar secuencias de *features* dependientes del tiempo que modelos como *Deep Learning* pueden explotar. Finalmente, usar modelos de aprendizaje profundo u otras técnicas avanzadas de ML puede capturar relaciones no lineales complejas. Por ejemplo, arquitecturas híbridas (RNN para secuencias + densas para datos clínicos) pueden procesar simultáneamente series de glucosa y variables clínicas. Sin embargo, para la realización de estas mejoras se

requiere principalmente de un conjunto de datos muy enriquecido en variabilidad de datos, y para su despliegue y aplicación futura.

6.3. Predicción en contexto de eventos de comida y en tiempo real

Para ofrecer predicciones en tiempo real, el sistema debe detectar cuándo ocurre un evento de comida y procesarlo de inmediato. Se propone implementar detección de eventos usando señales continuas (CGM, pulso, acelerómetro) como se ha implementado en otros estudios con mucho éxito, es decir, una implementación conjunta de un modelo que detecta el inicio de eventos de ingesta de alimentos, combinado con el modelo de predicción de carbohidratos.

Además, más allá de los carbohidratos, el sistema puede ampliarse para predecir ingesta de otros macronutrientes dado que, como se discutió, las proteínas, grasas y fibra también tienen un rol principal en la respuesta glucémica postprandial moderando el pico de glucosa. Adicionalmente, la plataforma podría predecir la evolución futura de la glucemia postprandial como se ha logrado en diversos estudios, lo cual es útil para alertar hipoglucemias/hiperglucemias inminentes.

7. CONCLUSIONES

El presente trabajo ha abordado el desarrollo de un sistema de predicción de carbohidratos ingeridos a partir de eventos de comida, utilizando información fisiológica, entre ella principalmente la respuesta glucémica postprandial recolectada mediante sensores de glucosa continua (CGM), así como información contextual, dispositivos *wearables*, registros nutricionales y otras variables demográficas, fisiológicas y clínicas.

A través del uso de un enfoque basado en aprendizaje supervisado, específicamente del modelo de regresión XGBRegressor, se buscó estimar con precisión la cantidad de carbohidratos consumidos en situaciones cotidianas, incorporando múltiples dimensiones de datos: respuesta glucémica postprandial, actividad física, parámetros clínicos y microbioma intestinal, entre otros. La calidad y riqueza del dataset utilizado, desarrollado por Gutierrez-Osuna et al. (2025), ha permitido explorar relaciones complejas entre estos factores, sentando las bases para futuras soluciones de nutrición personalizada en tiempo real.

Si bien el rendimiento del modelo actual ($R^2 \approx 0.3$) refleja una capacidad predictiva aún limitada, este valor resulta comprensible dada la alta variabilidad interindividual y la complejidad del fenómeno nutricional, así como la variabilidad en el conjunto de datos actual, y el reto que se tomó al implementar variables en un enfoque no se habían implementado. Lejos de constituir una limitación definitiva, estos resultados destacan el potencial de implementar modelos adaptativos, capaces de ajustarse al comportamiento alimentario individual mediante aprendizaje continuo. Esta perspectiva apunta hacia un enfoque más holístico y personalizado, alineado con las tendencias actuales en salud digital y prevención proactiva de enfermedades metabólicas.

Además, la creación de perfiles de alimentos según sus nutrientes y la respuesta glucémica que generan representa una herramienta valiosa para la clasificación y agrupamiento de comidas en función de su impacto metabólico. Esta estrategia permite no solo mejorar la precisión de los modelos predictivos al identificar patrones alimentarios comunes, sino también facilitar la toma de decisiones personalizadas sobre la dieta. A

través de técnicas de *clustering* y análisis multivariado, es posible detectar subconjuntos de alimentos que provocan respuestas similares en determinados grupos de personas, lo que puede ser clave para el diseño de recomendaciones nutricionales adaptadas al perfil glucémico individual. En un contexto clínico, esto contribuiría al desarrollo de intervenciones dietéticas más efectivas, sostenibles y basadas en evidencia.

Finalmente, se ha propuesto una arquitectura simplificada y factible en la nube utilizando servicios de Amazon Web Services (AWS), que permite la ingesta de datos en tiempo real desde dispositivos *wearables*, el procesamiento mediante funciones *serverless* y la inferencia con modelos desplegados en Amazon SageMaker. Esta infraestructura, pensada para escalar de manera progresiva, cumple con los estándares de seguridad y privacidad exigidos para el manejo de datos sensibles de salud, a la vez que habilita la integración futura con aplicaciones móviles y ecosistemas como Apple Health o MyFitnessPal.

En conjunto, este proyecto no solo demuestra la viabilidad técnica de una solución de predicción nutricional automatizada, sino que también traza un camino claro hacia la construcción de herramientas accesibles, inteligentes y clínicamente útiles en el marco de la nutrición de precisión.

8. BIBLIOGRAFÍA

Anthimopoulos, M., Dehais, J., Shevchik, S., Ransford, B. H., Duke, D., Diem, P., & Mougialakakou, S. (2015). *Computer vision-based carbohydrate estimation for type 1 patients with diabetes using smartphones*. Journal of diabetes science and technology, 9(3), 507–515. <https://doi.org/10.1177/1932296815580159>.

Amazon Web Services. (s.f.). *Amazon Relational Database Service*. Recuperado desde <https://aws.amazon.com/rds/> el 31 de mayo de 2025.

Amazon Web Services. (s.f.). *Amazon API Gateway*. Recuperado desde <https://aws.amazon.com/es/api-gateway/> el 31 de mayo de 2025.

Amazon Web Services. (s.f.). *AWS Glue*. Recuperado desde <https://aws.amazon.com/glue/?ams%23interactive-card-vertical%23pattern-data.filter=%257B%2522filters%2522%253A%255B%255D%257D> el 31 de mayo de 2025.

Amazon Web Services. (s.f.). *AWS IoT Core*. Recuperado desde <https://aws.amazon.com/iot-core/> el 31 de mayo de 2025.

Amazon Web Services. (2025). *Developer Guide: Amazon Kinesis Data Streams*. Recuperado desde <https://docs.aws.amazon.com/pdfs/streams/latest/dev/kinesis-dg.pdf#introduction> el 31 de mayo de 2025.

Amazon Web Services. (2025). *User Guide: Amazon CloudWatch*. Recuperado desde <https://docs.aws.amazon.com/pdfs/AmazonCloudWatch/latest/monitoring/acw-ug.pdf#WhatIsCloudWatch> el 31 de mayo de 2025.

Amazon Web Services. (2025). *User Guide: Amazon Simple Storage Service*. Recuperado desde https://docs.aws.amazon.com/es_es/AmazonS3/latest/userguide/s3-userguide.pdf el 31 de mayo de 2025.

Amazon Web Services. (s.f.). *¿Qué es AWS Lambda?* Recuperado desde https://docs.aws.amazon.com/es_es/lambda/latest/dg/welcome.html el 31 de mayo de 2025.

Amazon Web Services. (s.f.). *¿What is Amazon SageMaker AI?* Recuperado desde <https://docs.aws.amazon.com/sagemaker/latest/dg/whatis.html> el 31 de mayo de 2025.

American Diabetes Association. (s.f.). *Carb Counting and Diabetes*. Recuperado desde <https://diabetes.org/food-nutrition/understanding-carbs/carb-counting-and-diabetes> el 20 de mayo de 2025.

American Diabetes Association. (s.f.). *Understanding Carbs*. Recuperado desde <https://diabetes.org/food-nutrition/understanding-carbs> el 20 de mayo de 2025.

Amorim, D., Miranda, F., Santos, A., Graça, L., Rodrigues, J., Rocha, M., Pereira, M. A., Sousa, C., Felgueiras, P., & Abreu, C. (2024). *Assessing Carbohydrate Counting Accuracy: Current Limitations and Future Directions*. *Nutrients*, 16(14), 2183. <https://doi.org/10.3390/nu16142183>.

Bellissimo, N., & Akhavan, T. (2015). *Effect of Macronutrient Composition on Short-Term Food Intake and Weight Loss*. Elsevier. <https://doi.org/10.3945/an.114.006957>.

CDC. (s.f.). *Monitoreo del nivel de azúcar en la sangre*. Recuperado desde <https://www.cdc.gov/diabetes/es/diabetes-testing/monitoreo-del-nivel-de-azucar-en-la-sangre.html> el 20 de mayo de 2025.

Chan, N., Li, W., Aung, T., Bazuaye, E., & Montero, R. (2023). *Machine learning–based time in patterns for blood glucose fluctuation pattern recognition in type 1 diabetes management: Development and validation study*. *JMIR AI*, 2(e45450). <https://doi.org/10.2196/45450>.

Cheng, K., Li, Y., & Cheng, J. (2016). *The Areas Under Curves (AUC) used in diabetes research: Update view*. Recuperado desde <https://www.oatext.com/the-areas->

[under-curves-auc-used-in-diabetes-research-update-view.php](#) el 21 de mayo de 2025.

Chotwanvirat, P., Hnoohom, N., Rojroongwasinkul, N., & Kriengsinyos, W. (2021). *Feasibility Study of an Automated Carbohydrate Estimation System Using Thai Food Images in Comparison With Estimation by Dietitians*. *Frontiers in Nutrition*. <https://doi.org/10.3389/fnut.2021.732449>.

Clínica Universidad de Navarra. (s.f.). *Tabla con el índice glucémico de los alimentos*. Recuperado desde <https://www.cun.es/chequeos-salud/vida-sana/nutricion/tabla-alimentos-indice-glucemico> el 21 de mayo de 2025.

Cummings, J., Roberfroid, M., Andersson, H., Barth, C., Fero-Luzi, A., Ghooos, Y., Hermnsen, K., James, W., Korver, O., Lairon, D., Pascal, G., & Voragen, A. (1997). *A new look at dietary carbohydrate: chemistry, physiology and health*. *European Journal of Clinical Nutrition*. <https://doi.org/10.1038/sj.ejcn.1600427>.

Das, A., Do, E., Glanz, N., Bevier, W., Santiago, R., Kerr, D., Mortazavi, B. J., & Gutierrez-Osuna, R. (2024). *Macronutrient constraints and priors improve carbohydrate predictions from continuous glucose monitors*. *International Conference on Body Sensor Networks (BSN)* (pp. 1–4). IEEE. <https://doi.org/10.1109/BSN63547.2024.10780739>

Deeb, A., Al Hajeri, A., Alhmoudi, I., & Nagelkerke, N. (2017). *Accurate Carbohydrate Counting Is an Important Determinant of Postprandial Glycemia in Children and Adolescents With Type 1 Diabetes on Insulin Pump Therapy*. *Journal of diabetes science and technology*, 11(4), 753–758. <https://doi.org/10.1177/1932296816679850>.

Dexcom. (s.f.). *how it works*. Recuperado desde <https://provider.dexcom.com/products/dexcom-g6-pro/how-it-works#:~:text=1> el 22 de mayo de 2025.

- Dimitriadis, G. D., Maratou, E., Kountouri, A., Board, M., & Lambadiari, V. (2021). *Regulation of Postabsorptive and Postprandial Glucose Metabolism by Insulin-Dependent and Insulin-Independent Mechanisms: An Integrative Approach*. Nutrients. <https://doi.org/10.3390/nu13010159>.
- Englyst, K. N., & Englyst, H. N. (2005). *Carbohydrate bioavailability*. British Journal of Nutrition. <https://doi.org/10.1079/BJN20051457>.
- EPDATA. (2022). *La diabetes en España y en el mundo, en datos y gráficos*. EuropaPress. Recuperado desde <https://www.epdata.es/datos/diabetes-espana-datos-graficos/472> el 20 de mayo de 2025.
- Evenepoel, C., Clevers, E., Deroover, L., & Van, W. (2020). *Accuracy of Nutrient Calculations Using the Consumer-Focused Online App MyFitnessPal: Validation Study*. Journal of Medical Internet Research. <http://dx.doi.org/10.2196/18237>.
- Galindo, R., Migdal, A., Davis, G., Urrutia, M., Albury, B., Zambrano, C., Vellanki, P., Pasquel, F., Fayfman, M., Peng, L., & Umpierrez, G. (2020). *Comparison of the FreeStyle Libre Pro Flash Continuous Glucose Monitoring (CGM) system and point-of-care capillary glucose testing in hospitalized patients with type 2 diabetes treated with basal-bolus insulin regimen*. Diabetes Care, 43(11), 2730–2735. <https://doi.org/10.2337/dc19-2073>.
- GEMCO Medical. (s.f.). *Dexcom G6 Pro Continuous Glucose Monitoring (CGM) System*. Recuperado desde <https://www.dexcompro.com/> el 22 de mayo de 2025.
- Gioia, S., Vlasac, I., Babazadeh, D., Fryou, N. L., Do, E., Love, J., Robbins, R., Dashti, H. S., & Lane, J. M. (2023). *Mobile Apps for Dietary and Food Timing Assessment: Evaluation for Use in Clinical Research*. JMIR formative research, 7, e35858. <https://doi.org/10.2196/35858>.
- Gutierrez-Osuna, R., Kerr, D., Mortazavi, B., & Das, A. (2025). *CGMacros: a scientific dataset for personalized nutrition and diet monitoring (version 1.0.0)*. PhysioNet. <https://doi.org/10.13026/3z8q-x658>.

Huo, Z., Mortazavi, B. J., Chaspari, T., Deutz, N., Ruebush, L., & Gutierrez-Osuna, R. (2019). *Predicting the meal macronutrient composition from continuous glucose monitors*. IEEE EMBS International Conference on Biomedical & Health Informatics (BHI) (pp. 1–4). IEEE. <https://doi.org/10.1109/BHI.2019.8834488>.

IBM. (2021). *What is machine learning?* Recuperado desde <https://www.ibm.com/think/topics/machine-learning> el 20 de mayo de 2025.

InterSystems. (s.f.). *InterSystems presenta HealthShare® Health Connect Cloud*. Recuperado desde <https://www.intersystems.com/es/noticias/healthshare-health-connect-cloud/> el 31 de mayo de 2025.

International Diabetes Federation. (s.f.). *Sobre la diabetes*. Recuperado desde <https://idf.org/about-diabetes/what-is-diabetes/> el 20 de mayo de 2025.

Katsumi, I., & Yabe, D. (2023). *Dietary and Nutritional Guidelines for People with Diabetes*. Nutrients. <https://doi.org/10.3390/nu15204314>.

Linus Pauling Institute. (2016). *Glycemic Index and Glycemic Load*. Recuperado desde <https://lpi.oregonstate.edu/mic/food-beverages/glycemic-index-glycemic-load> el 21 de mayo de 2025.

Luna López, V., López Medina, J. A., Vázquez Gutiérrez, M., & Fernández Soto, M. L. (2014). *Hidratos de carbono: actualización de su papel en la diabetes mellitus y la enfermedad metabólica*. Nutrición Hospitalaria. Recuperado desde <https://scielo.isciii.es/pdf/nh/v30n5/05revision04.pdf> el 21 de mayo de 2025.

MedlinePlus. (s.f.). *Índice glucémico y diabetes*. Biblioteca Nacional de Medicina de Estados Unidos. Recuperado desde <https://medlineplus.gov/spanish/ency/patientinstructions/000941.htm> el 21 de mayo de 2025.

Medtronic. (2022). *Guía de conteo de carbohidratos: diferentes métodos de conteo de carbohidratos*. Recuperado desde <https://www.medtronic-diabetes.com/es->

ES/blog/guia-de-contaje-de-carbohidratos-diferentes-metodos-de-contaje-de-carbohidratos el 20 de mayo de 2025.

Mosquera-Lopez, C., Wilson, L. M., El Youssef, J., Hilts, W., Leitschuh, J., Branigan, D., Gabo, V., Eom, J. H., Castle, J. R., & Jacobs, P. G. (2023). *Enabling fully automated insulin delivery through meal detection and size estimation using artificial intelligence*. npj Digital Medicine, 6, Article 39.
<https://doi.org/10.1038/s41746-023-00783-1>.

Naska, A., Lagiou, A., & Lagiou, P. (2017). *Dietary assessment methods in epidemiological research: current state of the art and future prospects*. F1000Research, 6, 926. <https://doi.org/10.12688/f1000research.10703.1>.

Organización Mundial de la Salud. (2024). *DIABETES*. Recuperado desde <https://www.who.int/es/news-room/fact-sheets/detail/diabetes> el 20 de mayo de 2025.

Organización Mundial de la Salud. (2024). *Enfermedades no transmisibles*. Recuperado desde <https://www.who.int/es/news-room/fact-sheets/detail/noncommunicable-diseases> el 20 de mayo de 2025.

Organización Mundial de la Salud. (2025). *Obesidad y sobrepeso*. Recuperado desde <https://www.who.int/es/news-room/fact-sheets/detail/obesity-and-overweight> el 20 de mayo de 2025.

ResearchGate. (s.f.). FreeStyle Libre Pro (Abbott Japan Co., Ltd.). Recuperado desde https://www.researchgate.net/figure/Free-Style-Libre-ProR-Abbott-Japan-Co-Ltd-On-the-left-the-device-to-read-data-by_fig1_340799160 el 21 de mayo de 2025.

Rodboard, D. (2016). *Continuous Glucose Monitoring: A Review of Successes, Challenges, and Opportunities*. Diabetes Technology & Therapeutics.
<https://doi.org/10.1089/dia.2015.0417>.

Snorgaard, O., Poulsen, G. M., Andersen, H. K., & Astrup, A. (2017). *Systematic review and meta-analysis of dietary carbohydrate restriction in patients with type 2*

diabetes. BMJ open diabetes research & care, 5(1), e000354.

<https://doi.org/10.1136/bmjdr-2016-000354>.

Sklearn. (s.f.). *Clustering*. Recuperado desde <https://scikit-learn.org/stable/modules/clustering.html> el 27 de mayo de 2025.

Sklearn. (s.f.). *RandomForestRegressor*. Recuperado desde <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html#sklearn.ensemble.RandomForestRegressor> el 26 de mayo de 2025.

Sklearn. (s.f.). *StackinRegressor*. Recuperado desde <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.StackingRegressor.html#sklearn.ensemble.StackingRegressor> el 26 de mayo de 2025.

Sulik, B., Bell, K., Willis, H., & Buckingham, B. (s.f.). *Carb counting for bolus insulin dosing: Consider fat and protein content of diet as well*. Recuperado desde <https://www.ccjm.org/page/ada-2021/carb-counting> el 20 de mayo de 2025.

van Doorn, W. P. T. M., Foreman, Y. D., Schaper, N. C., Savelberg, H. H. C. M., Koster, A., van der Kallen, C. J. H., Wesselius, A., Schram, M. T., Henry, R. M. A., Dagnelie, P. C., de Galan, B. E., Bekers, O., Stehouwer, C. D. A., Meex, S. J. R., & Brouwers, M. C. G. J. (2021). *Machine learning-based glucose prediction with use of continuous glucose and physical activity monitoring data: The Maastricht Study*. PloS one, 16(6), e0253125. <https://doi.org/10.1371/journal.pone.0253125>.

Vlachos, D., Malisova, S., Lindberg, F. A., & Karaniki, G. (2020). *Glycemic index (GI) or glycemic load (GL) and dietary interventions for optimizing postprandial hyperglycemia in patients with T2 diabetes: A review*. Nutrients, 12(6), 1561. <https://doi.org/10.3390/nu12061561>.

xgboost. (s.f.). XGBoost Documentation. Recuperado desde https://xgboost.readthedocs.io/en/release_3.0.0/ el 26 de mayo de 2025.

Yamamoto, K., Yoshimura, M., Ueno, Y., Kido, H., & Nakayama, A. (2024). *Use of Artificial Intelligence-Based Food Recognition and Nutritional Information*

Estimation: Systematic Review and Meta-Analysis. *Nutrients*, 16(12), 2573.
<https://doi.org/10.3390/nu16122573>.

Yera, R., Alzahrani, A. A., Martínez, L., & Rodríguez, R. M. (2023). *A Systematic Review on Food Recommender Systems for Diabetic Patients*. *International journal of environmental research and public health*, 20(5), 4248.
<https://doi.org/10.3390/ijerph20054248>.

Zahedani, A., McLaughlin, T., Veluvali, A., Aghaeepour, N., Hosseinian, A., Agarwal, S., Ruan, J., Tripathi, S., Woodward, M., Hashemi, N., & Snyder, M. (2023) *Digital health application integrating wearable data and behavioral patterns improves metabolic health*. *npj Digit. Med.* <https://doi.org/10.1038/s41746-023-00956-y>.

Zeevi, D., Korem, T., Zmora, N., Israeli, D., Rothschild, D., Weinberger, A., Ben-Yacov, O., Lador, D., Avnit-Sagi, T., Lotan-Pompan, M., Suez, J., Mahdi, J. A., Matot, E., Malka, G., Kosower, N., Rein, M., Zilberman-Schapira, G., Dohnalová, L., Pevsner-Fischer, M., Bikovsky, R., Halpern, Z., Elinav, E., & Segal, E. (2015). *Personalized Nutrition by Prediction of Glycemic Responses*. Elsevier Inc.
<https://doi.org/10.1016/j.cell.2015.11.001>.

Zhang, L., Misir, A., Boshuizen, H., & Ocké, M. (2021). *A Systematic Review and Meta-Analysis of Validation Studies Performed on Dietary Record Apps*. *Advances in nutrition* (Bethesda, Md.), 12(6), 2321–2332.
<https://doi.org/10.1093/advances/nmab058>.

Zheng, M., Ni, B., & Kleinberg, S. (2019). *Automated meal detection from continuous glucose monitor data through simulation and explanation*. *Journal of the American Medical Informatics Association: JAMIA*, 26(12), 1592–1599.
<https://doi.org/10.1093/jamia/ocz159>

9. ANEXOS

Anexo I

El *dataset* utilizado para procesarlos, entrenar y evaluar los modelos de predicción es el publicado por Gutierrez-Osuna et al. (2025), titulado “A Multimodal Dataset for Personalized Nutrition and Glycemic Response Modeling”.

Este conjunto de datos se encuentra disponible públicamente en <https://doi.org/10.13026/3z8q-x658>.

El archivo incluye registros de sensores CGM, datos de actividad física, registros alimentarios, imágenes, parámetros clínicos y del microbioma de 45 participantes. Se optó por este *dataset* por su riqueza multimodal y por ser el único conjunto de datos públicos de este tipo disponible a la fecha.

Para facilitar su consulta, se adjunta el archivo comprimido que contiene el *dataset* original: CGMacro.zip

Anexo II

El desarrollo del modelo de predicción se llevó a cabo en un entorno Python mediante un notebook ejecutado en Visual Studio Code. En dicho notebook se encuentran todas las fases del pipeline: carga de datos, limpieza, ingeniería de características, entrenamiento del modelo XGBRegressor, validación y evaluación de métricas.

Archivo incluido:

TFM_Prediccion_ingesta_carbohidratos_AlejandroMagdielMunizCorona

Anexo III

Se adjuntan los diccionarios de datos correspondientes a los distintos *datasets* utilizados en el presente trabajo, todos forman parte del mismo conjunto de datos original que se

presenta en el anexo I. Estos archivos contienen la descripción de las variables incluidas en los *datasets* empleados para el modelado y análisis, facilitando la comprensión de su estructura y contenido.

Los archivos disponibles son los siguientes:

- DataDictionary.pdf: Documento general en formato PDF con la descripción consolidada de las variables.
- DataDictionary_Bio.csv: Diccionario de variables biométricas y antropométricas.
- DataDictionary_CGMacros-00X.csv: Diccionario de variables relacionadas con los eventos de comida y composición nutricional
- DataDictionary_Gut_Health_Test.csv: Diccionario de variables provenientes de las pruebas de salud intestinal
- DataDictionary_Microbes.csv: Diccionario de variables asociadas al microbioma intestinal.

Estos recursos se incluyen como material complementario para facilitar la replicabilidad y comprensión del estudio.